CORRDIFF

Relatório Especializado - Fases 15, 16 e 17

Protocolo temporal formal, baselines clássicos, métricas e desenho das ablações de condicionamento

Projeto de Mestrado - ERA5 -> Radar Sumaré
Dataset autoritativo: 84.684 timestamps | 1.016.208 patches | 12 predictors ERA5 raw
Status das Fases 15-17: concluídas / PASS
Versão consolidada - outubro de 2026

Fase 15	Split temporal formal e governança contra leakage
Fase 16	Baselines clássicos, protocolo de métricas e handoff NVIDIA
Fase 17	Desenho formal das ablações e campanhas Stage R / Stage D
Objetivo conjunto	Transformar o bloco diagnóstico em um experimento de treinamento reprodutível

Resumo executivo

As Fases 15, 16 e 17 formam o bloco de governança experimental que conecta o diagnóstico científico das Fases 0-14 ao treinamento nativo NVIDIA CorrDiff. A Fase 15 congela a separação temporal dos dados, impõe purge de ±48 h, mantém todos os 12 patches de cada timestamp no mesmo split e bloqueia 2023/2024 durante o desenvolvimento. A Fase 16 define o piso experimental com baselines clássicos, normalização train-only e um protocolo multimetric capaz de revelar falhas em extremos que RMSE/MAE globais esconderiam. A Fase 17 transforma as conclusões sobre umidade, térmica, dinâmica e variáveis derivadas em 11 ablações pré-registradas, executadas em duas etapas no ambiente NVIDIA.

> **O resultado metodológico conjunto é que, antes de iniciar o treinamento completo, já estão congelados: dados de treino/validação/teste, regras de leakage, normalização, referências clássicas, thresholds físicos, escalas do FSS, política de reporte, famílias de conditioning, seeds e comparações científicas. Isso reduz o risco de tuning orientado ao teste e fortalece a validade das conclusões futuras sobre o CorrDiff.**

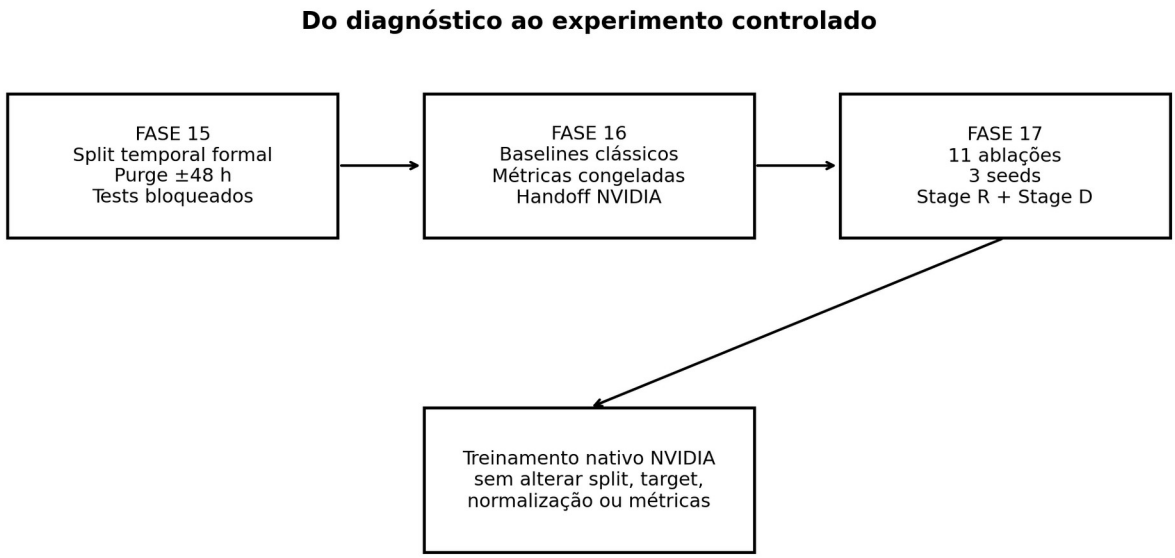


Figura 1 - Encadeamento metodológico das Fases 15-17.

1. Papel das Fases 15-17 no projeto

Até a Fase 14, o projeto havia demonstrado que o ERA5 descreve principalmente o estado ambiental de larga escala, enquanto o radar contém estrutura espacial fina, esparsa e parcialmente multimodal. Também foram identificadas forte dependência temporal, sazonalidade, regimes meteorológicos estáveis, covariate shift e cobertura muito incompleta em 2024. As Fases 15-17 não procuram novas correlações meteorológicas; elas convertem essas evidências em regras formais de experimentação.

Fase	Pergunta central	Produto
15	Onde o modelo pode aprender e onde pode ser avaliado sem leakage?	Split temporal, purge, testes bloqueados, normalização train-only.
16	O que o CorrDiff precisa superar e como será medido?	Baselines clássicos, métricas congeladas e handoff NVIDIA.
17	Quais partes do conditioning realmente importam?	Matriz de 11 ablações, 3 seeds e dois estágios experimentais.

2. Fase 15 - Split temporal formal

2.1 Motivação: por que um split aleatório seria inadequado

A dependência temporal observada nas fases anteriores torna inadequado misturar timestamps próximos entre train e validation/test. Eventos intensos apresentam memória de curto prazo e os regimes ERA5 são fortemente persistentes. Além disso, os 12 patches de um mesmo timestamp representam a mesma situação meteorológica e possuem sobreposição espacial. Um split aleatório poderia colocar amostras quase duplicadas ou altamente relacionadas em conjuntos diferentes, inflando artificialmente a generalização.

2.2 Protocolo temporal congelado

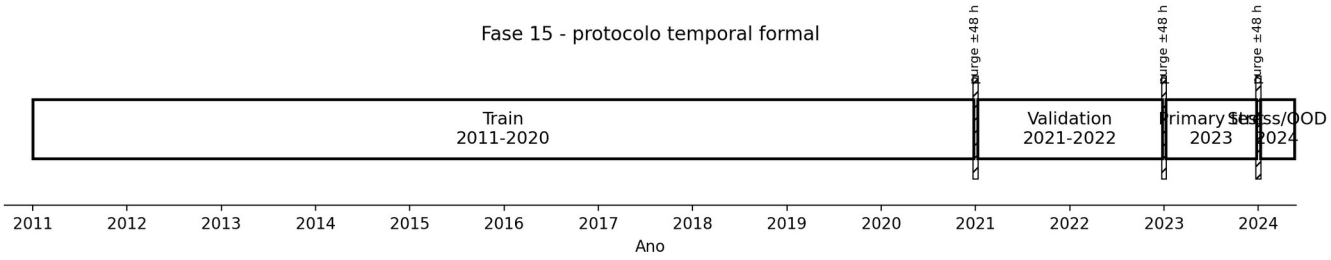


Figura 2 - Split temporal formal e buffers de purga.

Split	Período	Timestamps	Patches	Papel
Train	2011-2020	63.587	763.044	Ajuste dos parâmetros e estatísticas.

Split	Período	Timestamps	Patches	Papel
Validation	2021-2022	12.828	153.936	Seleção de configuração e checkpoints.
Primary test	2023	4.966	59.592	Generalização cronológica principal.
Stress/OOD	2024	3.108	37.296	Avaliação adversa sob coverage/shift.
Purge	fronteiras ±48 h	195	2.340	Redução de leakage por persistência temporal.

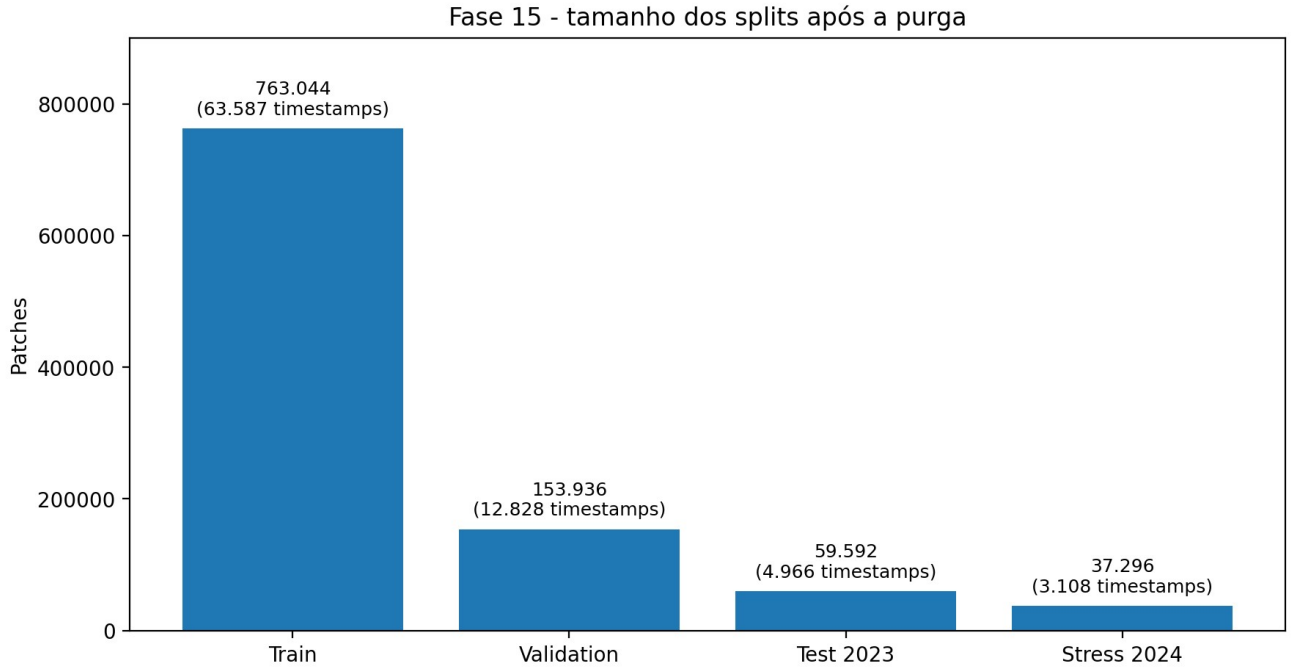


Figura 3 - Número de patches e timestamps retidos após a purga.

2.3 Regras de governança

- Todos os 12 patches de um timestamp pertencem ao mesmo split; não existe separação de patches do mesmo horário entre treino e validação/teste.
- O target não foi usado para balancear artificialmente os splits; as diferenças de prevalência entre períodos são preservadas como parte da generalização temporal.
- Médias, desvios-padrão e demais transformações dependentes de dados são ajustados somente no train durante desenvolvimento.
- 2023 e 2024 não participam da escolha de canais, arquitetura, loss, learning rate, sampler, checkpoint ou critérios de seleção.
- 2024 é reportado separadamente como stress/OOD e nunca é combinado ao headline do teste primário de 2023.

2.4 O que os splits revelam

Os splits preservam mudanças reais de distribuição. A taxa de eventos >=45 não é idêntica entre train, validation, 2023 e 2024, e a validation contém uma composição de eventos diferente do treino. Isso é desejável: o conjunto de validação funciona como um teste de robustez temporal durante o desenvolvimento, em vez de reproduzir uma distribuição artificialmente IID.

Split	Taxa >=45 (aprox.)	Interpretação
Train	8,3%	Referência histórica de ajuste.
Validation	5,3%	Período temporalmente distinto usado para seleção.
2023	8,9%	Teste primário bloqueado.
2024	9,3%	Stress/OOD; coverage muito incompleto.

> **Resultado principal da Fase 15: o ganho científico não é um score, mas a criação de uma avaliação cronológica defensável, com proteção explícita contra leakage temporal e espacial.**

3. Fase 16 - Baselines clássicos e protocolo de avaliação

A Fase 16 estabelece o piso experimental que os modelos nativos NVIDIA deverão superar. Uma proposta inicial incluiu baselines neurais paralelos; essa linha foi posteriormente substituída no protocolo efetivo por uma Fase 16 clássica, preservando o princípio de que o aprendizado neural formal deve ocorrer dentro do ambiente NVIDIA CorrDiff. Os resultados consolidados referem-se à avaliação efetiva v2.2.

3.1 Baselines clássicos

Baseline	Definição	Informação utilizada
Zero	Prediz target zero em todos os pixels.	Nenhuma; referência para a enorme massa de zeros.
Global mean	Campo médio do target log1p calculado no train.	Histórico global do treino.
Slot mean	Campo médio específico para cada uma das 12 posições de patch.	Histórico + posição/slot.
Mês×hora×slot	Climatologia local por mês, hora local e slot, com fallback.	Sazonalidade + ciclo diurno + geografia.
Persistência 1 h	Usa o radar observado exatamente em t-1 h.	Radar passado; referência lateral, não input-equivalente ao ERA5-only.

3.2 Normalização e proteção contra leakage

A normalização dos predictors é ajustada exclusivamente no train. Validation e futuros testes recebem as mesmas estatísticas. Essa regra é especialmente importante porque as Fases 13-14 mostraram covariate e regime-composition shift; recalcular normalização no futuro incorporaria informação que não estaria disponível em uma implantação real.

3.3 Protocolo multimetric congelado

Família	Métricas / suportes	Por que é necessária
Pontual	RMSE, MAE, bias em log1p e dBZ	Erro médio e viés global.
Categórica	20/30/40/45 dBZ: POD, FAR, CSI, ETS, F1, bias de frequência	Avaliar eventos que a massa de zeros esconde.
Espacial	FSS em 2, 4, 8 e 16 km	Tolerar pequenos deslocamentos e medir organização espacial.
Extremos	Máximo por patch; todos, >=30, >=40, >=45	Verificar suavização e intensidade dos núcleos.
Sazonal	DJF/MAM/JJA/SON	Detectar skill dependente da estação.

3.4 Auditoria da persistência e versão v2.2

A preparação da Fase 16 passou por duas correções importantes de calendário/timestamp. O manifesto temporal da Fase 15 passou a ser a fonte autoritativa, e a busca de t-1 h foi tornada robusta à resolução do dtype de datetime. A auditoria final recuperou exatamente 73.977 timestamps com lag de 1 h, coincidindo com a Fase 7. Na validation, a coorte persistence_common contém 138.600 dos 153.936 patches, cerca de 90%.

3.5 Resultado global das climatologias

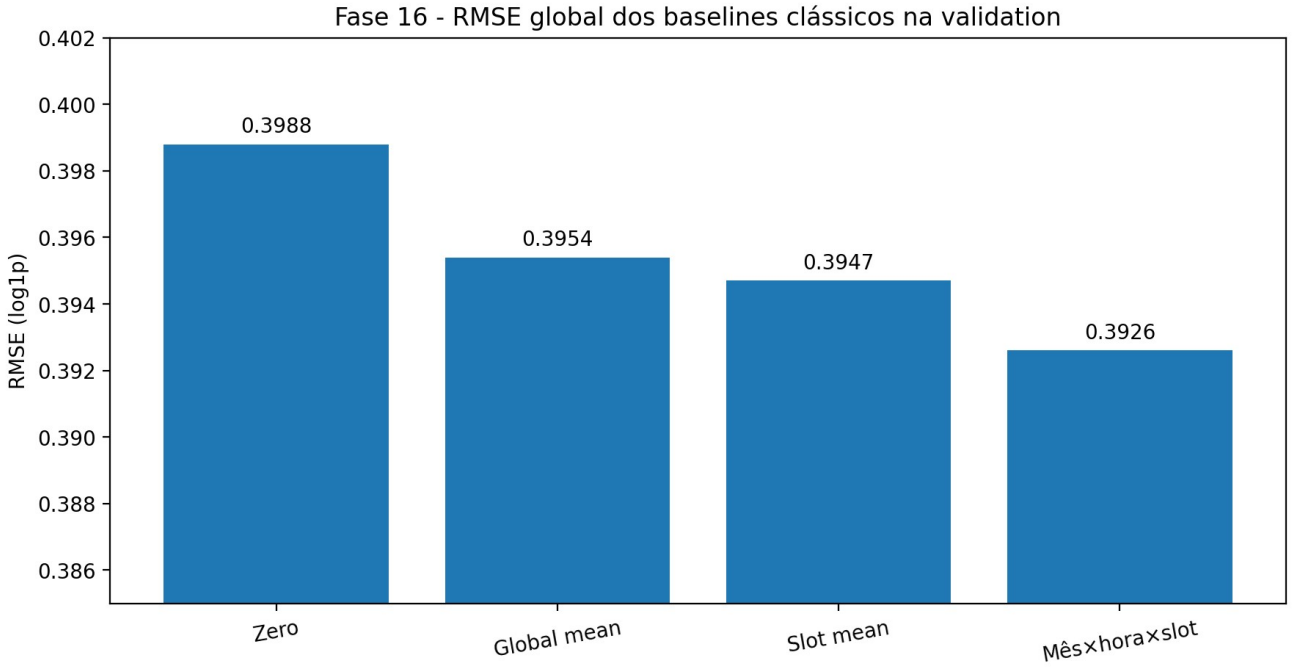


Figura 4 - RMSE global em log1p dos baselines clássicos.

A climatologia mês×hora×slot produz a melhor redução de RMSE entre as médias, mas o ganho é pequeno. Em MAE, o baseline zero pode ser competitivo ou melhor devido à enorme massa de pixels secos. Esse comportamento demonstra por que métricas médias isoladas não são suficientes.

3.6 Resultado crítico nos extremos

As climatologias médias praticamente não geram pixels acima de 30, 40 ou 45 dBZ. Como consequência, POD, CSI e FSS nesses thresholds são zero. Portanto, um método pode reduzir RMSE global e simultaneamente falhar de forma completa na representação de convecção intensa.

> **Este resultado estabelece uma exigência clara para o CorrDiff: superar médias não basta; o modelo precisa produzir eventos, intensidade e estrutura espacial realistas.**

3.7 Persistência: forte em intensidade, fraca em localização

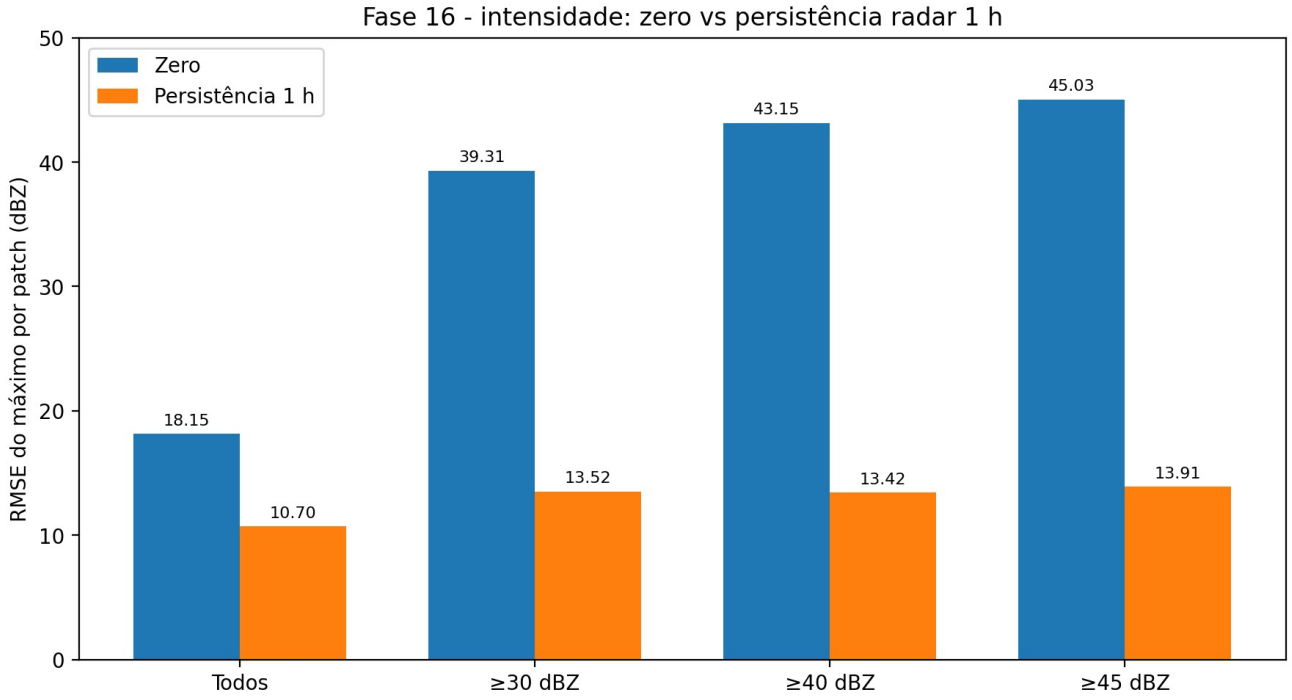


Figura 5 - RMSE do máximo por patch: baseline zero versus persistência radar de 1 h.

A persistência reduz fortemente o erro no máximo por patch, inclusive nos eventos >=45 dBZ. Entretanto, a coincidência pixelwise de extremos permanece muito baixa. Para >=45 dBZ, CSI é aproximadamente 0,0034, POD ~0,0063 e FAR ~0,993. Em >=40, CSI ~0,0069; em >=30, ~0,042. Assim, o radar anterior preserva informação sobre o estado/intensidade do patch, mas não determina a posição futura dos pixels extremos.

3.8 Handoff NVIDIA

A Fase 16 também formaliza a ponte de dados para o ambiente NVIDIA: índices de patches por split, normalização train-only, protocolo de métricas, contrato do dataset e metadados de preparação. O objetivo é impedir que a integração posterior altere silenciosamente a ordem dos canais, o target, os thresholds ou as regras de avaliação.

4. Fase 17 - Desenho formal das ablações de condicionamento

A Fase 17 não executa treinamento. Seu produto é um desenho experimental pré-registrado que converte as evidências meteorológicas das fases anteriores em comparações controladas. O objetivo é distinguir suficiência de uma família de predictors, necessidade condicional quando combinada às demais e benefício de representação das variáveis derivadas.

4.1 Famílias de canais

Família	Canais raw
Moisture	tcwv, r_850, r_500
Thermal	t2m, t_850, t_500

Família	Canais raw
Dynamics	u10, v10, u_850, v_850, u_500, v_500

Foram ainda congelados oito canais derivados: wind_speed_10, wind_speed_850, wind_speed_500, delta_t_500_850, delta_t_850_surface, delta_r_500_850, bulk_wind_diff_10_850 e bulk_wind_diff_850_500. Eles são transformações determinísticas dos raw; portanto podem facilitar representação/otimização, mas não adicionam informação independente.

4.2 Matriz de 11 ablações

ID	Configuração	Categoria	Pergunta
C00	raw12	Referência	Desempenho do conditioning completo original.
C01	moisture only	Suficiência	Quanto a umidade consegue explicar sozinha?
C02	thermal only	Suficiência	Quanto a família térmica consegue explicar sozinha?
C03	dynamics only	Suficiência	Quanto a dinâmica consegue explicar sozinha?
C04	no dynamics	Necessidade	O que se perde ao retirar dinâmica?
C05	no thermal	Necessidade	O que se perde ao retirar térmica?
C06	no moisture	Necessidade	O que se perde ao retirar umidade?
C07	raw12 + all derived	Representação	Derived facilitam aprendizado global?
C08	raw12 + moisture derived	Representação	Benefício de representação de umidade.
C09	raw12 + thermal derived	Representação	Benefício de representação térmica.
C10	raw12 + dynamics derived	Representação	Benefício de representação dinâmica.

4.3 Por que suficiência e necessidade não são equivalentes

Se C03 (dynamics only) apresentar baixo desempenho, isso mostra apenas que a dinâmica é insuficiente sozinha. Para concluir se a dinâmica agrega informação ao modelo completo, a comparação relevante é C00 versus C04. Essa distinção é essencial diante da colinearidade observada na Fase 12: uma família pode ter pouco skill isolado e ainda conter informação condicional útil quando combinada a outras.

4.4 Stage R - screening com regression model nativo

Todos os 11 experimentos são executados primeiro com o regression model nativo NVIDIA CorrDiff e com as seeds 42, 43 e 44. Isso produz 33 runs. Train é usado para ajuste e validation para checkpoint/avaliação; 2023/2024 permanecem inacessíveis.

4.5 Stage D - confirmação com CorrDiff

O estágio generativo completo é mais caro. Foram definidos cinco experimentos obrigatórios: C00, C04, C05, C06 e C07. Com três seeds, são 15 runs obrigatórios. C01, C02, C03, C08, C09 e C10 ficam opcionais sob regra pré-declarada de orçamento ou necessidade de resolver ambiguidades do Stage R. A decisão de executar opcionais deve ser documentada antes da execução correspondente, evitando cherry-picking.

4.6 Regras de comparabilidade

- Mesmo split e purge da Fase 15.
- Mesmo target e mesma geometria do dataset.
- Mesma arquitetura dentro de cada estágio, mesmo orçamento e mesma política de checkpoint.
- Mesma família de optimizer, learning-rate policy e batch-size policy.
- Mesmas seeds 42, 43 e 44.
- Normalização ajustada somente no train para exatamente os canais presentes em cada experimento.
- Resultados reportados por centro + dispersão; nunca selecionar apenas a melhor seed.
- 2023/2024 não participam da seleção de conditioning.

4.7 Hierarquia de métricas para seleção

A Fase 17 rejeita a ideia de selecionar um experimento por um único score. A leitura é hierárquica/Pareto: primeiro estrutura e eventos em >=30/40 por FSS/CSI; depois intensidade máxima condicionada a evento; >=45 como diagnóstico crítico secundário devido à raridade; e somente depois erro global. Em modelos probabilísticos, Brier, reliability/ECE e CRPS ou métrica equivalente devem ser incorporados conforme disponíveis no stack nativo.

4.8 Hipóteses pré-registradas

- Moisture pode reter maior sinal para ocorrência e eventos moderados.
- Thermal pode contribuir relativamente mais em thresholds altos.
- Dynamics pode ajudar organização espacial mesmo com correlação escalar fraca.
- Derived podem melhorar representação/otimização, sem adicionar informação nova.
- Leave-one-family-out pode revelar valor condicional escondido por multicolinearidade.

Essas afirmações são hipóteses experimentais, não conclusões da Fase 17.

5. Leitura integrada das Fases 15-17

As três fases fecham três fontes distintas de viés experimental. A Fase 15 impede leakage e tuning temporal indevido. A Fase 16 impede que métricas inadequadas ou referências fracas produzam uma falsa sensação de sucesso. A Fase 17 impede que a escolha de conditioning seja feita retrospectivamente após observar o teste. Em conjunto, elas criam uma cadeia de evidência reprodutível.

Risco metodológico	Mecanismo de controle
Leakage temporal / patches relacionados	Split cronológico, timestamp indivisível e purge ±48 h.
Normalização usando futuro	Estatísticas exclusivamente train-only.
RMSE baixo por excesso de zeros	Threshold metrics, FSS e métricas de extremos.
Comparação injusta com radar passado	Persistência reportada como referência lateral/persistence_common.
Escolha oportunista de canais	Matriz C00-C10 pré-registrada e seeds fixas.
Tuning no teste	2023 e 2024 bloqueados até design freeze.
Cherry-picking de seed	Reporte de todas as seeds e dispersão.

6. Principais pontos para o CorrDiff

1. O regression model e o diffusion model devem usar exatamente o protocolo temporal congelado; qualquer alteração de split durante o treinamento quebraria a comparabilidade com os baselines.
2. Superar RMSE climatológico não é evidência suficiente. O CorrDiff precisa produzir skill espacial e categórico nos thresholds 30/40 dBZ e representar a cauda de intensidade.
3. A persistência de 1 h mostra que a intensidade do estado convectivo possui memória, mas a localização pixelwise evolui rapidamente. Isso reforça o papel do componente generativo para representar realizações espaciais plausíveis.
4. O conditioning ERA5 deve ser estudado por famílias e não por coeficientes individuais. As ablações leave-one-family-out são particularmente importantes diante da multicolinearidade.
5. Derived devem ser avaliados como engenharia de representação, nunca como nova informação meteorológica.
6. A seleção de conditioning ocorre somente em train/validation. 2023 responde à generalização temporal principal; 2024 responde à robustez sob stress/OOD.
7. A avaliação final deve manter separadas ocorrência, intensidade, localização/estrutura e incerteza. Um modelo bom em apenas uma dessas dimensões não resolve o problema completo.

7. Principais pontos para a dissertação

8. As Fases 15-17 demonstram governança experimental prévia ao treinamento: split, métricas e ablações foram congelados antes de observar os testes. Isso fortalece a validade externa dos resultados futuros.
9. A dissertação pode separar claramente "desenvolvimento" de "avaliação final": 2011-2020 para ajuste, 2021-2022 para seleção, 2023 para teste primário e 2024 para stress/OOD.
10. O resultado da Fase 16 é uma evidência metodológica forte de que métricas médias são insuficientes em targets zero-inflated: climatologias melhoram RMSE mas têm skill nulo nos extremos.
11. A discrepância entre persistência de intensidade e coincidência pixelwise oferece uma ponte conceitual entre as análises de temporalidade e a necessidade de geração espacial probabilística.
12. A Fase 17 permite testar hipóteses meteorológicas por contraste controlado, distinguindo suficiência, necessidade condicional e benefício de representação.
13. A narrativa científica torna-se progressiva: diagnóstico do dataset -> desenho temporal -> baseline -> ablação -> integração NVIDIA -> treinamento -> teste fechado.

8. Texto sugerido para a seção metodológica da dissertação

"Após o bloco diagnóstico, foi estabelecido um protocolo temporal estritamente cronológico para reduzir leakage decorrente da forte dependência temporal do radar e dos regimes meteorológicos. O período 2011-2020 foi destinado ao treinamento, 2021-2022 à validação, 2023 ao teste primário e 2024 a uma avaliação separada de stress/OOD. Buffers de ±48 h foram aplicados nas fronteiras dos blocos, e todos os patches associados a um mesmo timestamp foram mantidos no mesmo split. Estatísticas de normalização e demais transformações dependentes dos dados foram ajustadas exclusivamente no conjunto de treinamento."

"Com o protocolo temporal congelado, foram avaliadas referências clássicas de complexidade crescente: zero, campo médio global, média por slot, climatologia mês-hora-slot e persistência radar de uma hora. Embora as climatologias reduzam modestamente o RMSE global, elas não produzem eventos nos thresholds de 30, 40 e 45 dBZ, apresentando skill categórico e espacial nulo nesses níveis. A persistência, por sua vez, reduz fortemente o erro da intensidade máxima por patch, mas possui baixa coincidência pixelwise nos extremos. Esses resultados motivam uma avaliação multimetric e reforçam a necessidade de representar explicitamente a variabilidade espacial condicional."

"Por fim, o conditioning foi organizado em um desenho de ablação pré-registrado com 11 configurações. As comparações distinguem suficiência de famílias isoladas, necessidade condicional por leave-one-family-out e benefício representacional de variáveis derivadas. Todos os experimentos aprendidos serão executados no ambiente NVIDIA CorrDiff com seeds fixas e sem acesso aos conjuntos de teste durante a seleção."

9. Rastreabilidade, versões e cautelas

- Fase 15: os números de splits apresentados neste relatório correspondem ao protocolo formal usado na apresentação consolidada do projeto.

- Fase 16: o README armazenado documenta uma proposta inicial mais ampla, que incluía baselines neurais. O protocolo efetivo consolidado adotado aqui é o clássico v2.2, no qual o aprendizado neural é reservado ao ambiente NVIDIA.
- Os resultados v2.2 de persistência devem ser interpretados em persistence_common quando comparados diretamente a métodos que não exigem t-1 h.
- Fase 17: PASS significa desenho experimental validado, não superioridade de qualquer configuração C00-C10. Nenhum resultado de treino é inferido antes da campanha nativa.
- 2023 e 2024 permanecem fechados para seleção de modelo. Qualquer uso desses conjuntos durante tuning deve ser tratado como quebra do protocolo experimental.

10. Conclusão

As Fases 15, 16 e 17 completam a transição entre exploração científica e experimento controlado. A Fase 15 protege a validade temporal; a Fase 16 define referências e métricas capazes de detectar falhas relevantes em um target esparso e extremo; e a Fase 17 transforma as hipóteses meteorológicas em comparações pré-registradas que poderão ser executadas no regression model e no CorrDiff nativos. O principal resultado desse bloco não é um único número de skill, mas a construção de um protocolo que torna os resultados futuros auditáveis, comparáveis e defensáveis academicamente.

> **Para o CorrDiff, a consequência direta é que o treinamento completo já possui um contrato claro: aprender em 2011-2020, selecionar em 2021-2022, não tocar em 2023/2024 durante desenvolvimento, superar referências clássicas não apenas em erro médio mas em eventos e estrutura espacial, e testar o valor do conditioning através de ablações controladas. Para a dissertação, esse bloco fornece a evidência de que o desenho experimental foi definido antes da avaliação final, reduzindo risco de leakage, cherry-picking e conclusões orientadas ao teste.**

Base documental utilizada

- Apresentação CorrDiff - Formação do Dataset e Principais Resultados, Fases 0 a 17: slides das Fases 15, 16 e 17.
- README_PHASE16.md: definição dos baselines, normalização, métricas, thresholds, FSS, política de checkpoint e proteção dos testes.
- Resultados consolidados do projeto para as versões efetivas das Fases 15-17, incluindo a auditoria v2.2 de persistência e o contrato experimental da Fase 17.