Dataset ERA5 e Radar Sumaré

Características construção e limitações

Projeto RioNowcastDF e CorrDiff | Relatório técnico | 18 de outubro de 2026

Este documento descreve o conjunto de pares meteorológicos utilizado no projeto: campos ERA5 alinhados a refletividade do radar Sumaré, organizados em patches para aprendizado supervisionado e geração condicional. Explica a origem dos dados, as transformações, a estrutura de armazenamento, os resultados da caracterização e as condições necessárias para interpretar os experimentos.

A versão consolidada reúne 1.016.208 patches em 84.684 horários entre 2011 e 2024. O volume de patches não corresponde ao mesmo número de observações independentes: existe sobreposição espacial, persistência meteorológica e cobertura temporal incompleta. Essas características determinam o desenho de validação e a leitura das métricas. [1, 2]

Propriedade	Versão consolidada
Período de interesse	2011 a 2024
Horários disponíveis	84.684 de 122.736 esperados | 69,00%
Patches aceitos	1.016.208 | 12 por horário disponível
Entrada	12 canais ERA5 | 32 × 32 pixels
Alvo	Radar em log1p de dBZ não negativos
Geometria	Grade aproximada 70 × 84 | espaçamento nominal de 2 km
Amostragem espacial	Janela 32 × 32 | stride 16 | posições 3 × 4

Como utilizar este relatório

As seções 1 a 5 descrevem o contrato dos dados e o processo de criação. As seções 6 a 8 apresentam evidências e protocolo experimental. As seções 9 e 10 discutem limites e rastreabilidade. Os números consolidados são resultados documentados das auditorias anteriores; não representam uma nova execução do dataset na máquina do CEFET.

1 Finalidade e unidade de observação

Cada exemplo associa um campo multicanal ERA5 no instante t a um patch do radar no mesmo instante e na mesma janela espacial. O problema documentado é reconstrução ou downscaling condicional de um campo radar a partir do ambiente atmosférico de maior escala. Não há, nesse contrato básico, um horizonte de previsão futuro t + Δt. [1, 3]

O uso do nome RioNowcast não transforma automaticamente esse pareamento em nowcasting operacional. Uma avaliação de previsão exigiria definir antecedência, entradas disponíveis no horário de emissão, latência das fontes e alvo futuro. ERA5 é uma reanálise; a disponibilidade operacional precisa ser avaliada separadamente da validade do experimento retrospectivo.

Três unidades que não podem ser confundidas

Unidade	Significado
Timestamp	Um horário UTC com campos ERA5 e radar compatíveis.
Patch	Uma janela espacial de um timestamp. As 12 janelas se sobrepõem.
Pixel armazenado	Uma posição dentro de um patch. Um mesmo pixel geográfico pode ser contado mais de uma vez.

Uma taxa de timestamps com algum núcleo intenso mede ocorrência no domínio amostrado. Uma taxa de patches intensos depende da distribuição espacial desses núcleos. Uma frequência por pixel mede a ocupação na representação armazenada. Percentuais nessas três unidades não são intercambiáveis.

Domínio e período

O período pretendido vai de 1 de janeiro de 2011 a 31 de dezembro de 2024. A auditoria registra o primeiro horário efetivamente armazenado em 17 de janeiro de 2011 às 19 UTC e o último em 31 de dezembro de 2024 às 23 UTC. A grade alvo é regional, referente ao radar Sumaré, com aproximadamente 70 × 84 pixels. [1]

O builder inspecionado possui limites geográficos e resolução configuráveis. Seus valores padrão são latitude −23,5 a −22,25 e longitude −44,0 a −42,5, com 2 km nominais. Para reproduzir o conjunto exato, os argumentos e metadados da execução devem prevalecer sobre defaults do código. [3]

Generalização permitida

A evidência obtida descreve esse produto radar, esse domínio, os horários disponíveis e a representação em patches. Transferência para outros radares, outras regiões, resoluções ou produtos exige nova validação. Tampouco um resultado retrospectivo demonstra, por si só, habilidade operacional em tempo real.

2 Fontes e canais meteorológicos

O pipeline utiliza ERA5 single level e pressure level organizados em arquivos Parquet mensais. Os campos de pressão mantêm o nível atmosférico em uma coluna própria. Aliases de variáveis são resolvidos, níveis solicitados são verificados e duplicidades de coordenadas lógicas só podem ser consolidadas quando não há valores conflitantes. [3]

Ordem	Canal	Grandeza	Unidade usual
0	tcwv	Vapor de água integrado na coluna	kg/m²
1	t2m	Temperatura a 2 m	K
2–3	u10, v10	Componentes zonal e meridional a 10 m	m/s
4	t_850	Temperatura em 850 hPa	K
5	r_850	Umidade relativa em 850 hPa	%
6–7	u_850, v_850	Componentes do vento em 850 hPa	m/s
8	t_500	Temperatura em 500 hPa	K
9	r_500	Umidade relativa em 500 hPa	%
10–11	u_500, v_500	Componentes do vento em 500 hPa	m/s

A ordem acima é o contrato raw12 consolidado. As unidades indicadas são as convenções usuais das variáveis ERA5 e devem permanecer verificadas nos metadados da extração. Os defaults atuais do CLI do builder solicitam um conjunto mais amplo e diferente de variáveis; executar o script sem explicitar os canais não garante reproduzir raw12. [1, 3]

Famílias do condicionamento

Umidade reúne tcwv, r_850 e r_500. Temperatura reúne t2m, t_850 e t_500. Dinâmica reúne as seis componentes u e v. Essa organização permite comparar famílias nas ablações sem interpretar coeficientes isolados como importância causal. [2]

Produto radar

O builder consome grades NumPy float32 em cache, nomeadas por timestamp. Seu caminho de criação do cache parte de imagens PNG, converte RGB pela legenda configurada de refletividade e remapeia os valores para a grade geográfica. Não equivale a ingestão direta de volumes polares instrumentais com todos os campos originais do radar. [3]

O código encontra as duas cores de legenda mais próximas e calcula um valor interpolado a partir das distâncias RGB. Essa reconstrução depende da paleta, do produto gráfico e da correspondência entre pixels e coordenadas. Mudanças de legenda, anotações da imagem ou cores fora da legenda precisam de controle próprio; validade numérica não garante validade meteorológica.

3 Processo de criação e alinhamento

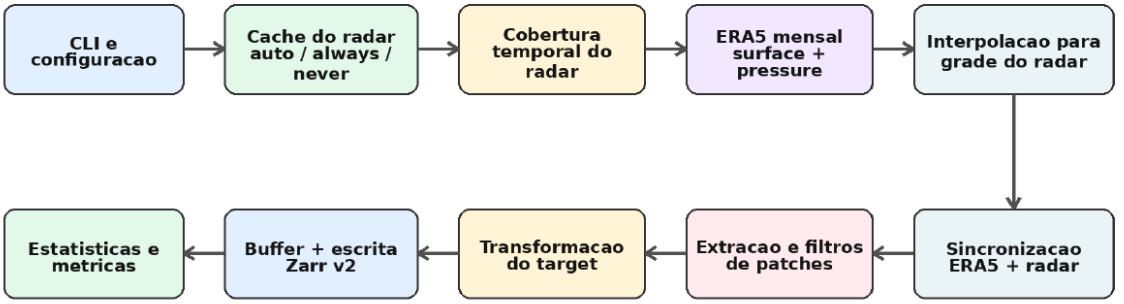


Figura 1 Fluxo do builder recuperado do material técnico do projeto. [4]

Preparar o cache e verificar disponibilidade

A execução estabelece intervalo temporal, domínio, variáveis, geometria e caminhos. O cache pode ser reutilizado, complementado ou exigido como pré existente. No modo auto, a presença de algum arquivo não prova completude; a cobertura deve ser verificada para a sequência horária solicitada. O gerador pode procurar PNGs em cadência de dois minutos, mas o dataset consolidado utiliza horários exatos. [3]

Reconstruir e interpolar os campos ERA5

Para cada timestamp, o builder reconstrói grades regulares de latitude e longitude, separa os níveis de pressão e interpola os cubos para os pontos da grade radar. A implementação usa RegularGridInterpolator com interpolação linear padrão, bounds_error=False e preenchimento externo por NaN. O resultado assume forma C × H × W. [3]

A interpolação coloca entrada e alvo na mesma geometria. Ela não cria informação observacional independente em 2 km. Pixels vizinhos do ERA5 remapeado compartilham informação dos mesmos pontos de origem e permanecem espacialmente suaves.

Sincronizar pelo instante exato

O builder requer radar e ERA5 no mesmo timestamp. Se o radar estiver ausente, inteiramente inválido, se faltar ERA5 ou se as formas espaciais divergirem, registra o motivo e não fabrica o par. Não há substituição silenciosa pelo horário mais próximo. A sequência resultante mantém lacunas reais. [3]

Preservar o tempo de referência

O armazenamento deve conservar uma referência temporal única e documentada. Análises de ciclo diurno usam America/Sao_Paulo e respeitam o histórico de horário de verão; simplesmente subtrair três horas para todos os anos não reproduz essa definição. [1]

4 Patches máscara e transformação do alvo

Depois do alinhamento do campo completo, uma janela de 32 × 32 avança 16 pixels por eixo. Na grade aproximada de 70 × 84, isso produz 3 posições em linhas e 4 em colunas: 12 patches por horário. O lado nominal de cada patch é 64 km e o deslocamento é 32 km. Janelas vizinhas compartilham metade da extensão de cada eixo. [1, 3]

A implementação armazena os deslocamentos patch_row e patch_col, e não apenas um número abstrato de slot. O laço usa apenas janelas completas, sem padding de borda. Para uma grade exatamente 70 × 84, os inícios são linhas 0, 16, 32 e colunas 0, 16, 32, 48; a união cobre 64 × 80 pixels. Essa consequência geométrica deve ser considerada ao reconstruir o domínio. [3]

Critérios de aceitação

O builder rejeita patches abaixo das frações mínimas configuradas de radar válido e de entrada finita. Os defaults inspecionados são 0,05 e 1,0, respectivamente, mas não constituem prova dos parâmetros usados na geração histórica. A auditoria consolidada encontrou 100% de pixels radar válidos no Zarr armazenado. Isso descreve o produto aceito, não a cobertura instrumental nem os dados descartados. [1, 3]

Semântica exata do alvo

Primeiro calcula-se mask = isfinite(radar), antes de qualquer preenchimento. Depois, NaN e infinitos são substituídos por zero; valores negativos são cortados em zero; por fim aplica-se target = log1p(radar_preenchido_e_clipado). A máscara é armazenada separadamente. [3]

Valor original	Máscara	Alvo armazenado	Interpretação
25 dBZ	1	ln(26)	Valor válido positivo
0 dBZ	1	0	Zero válido
Valor negativo	1	0	Informação negativa perdida
NaN ou infinito	0	0	Inválido preenchido

expm1(target) recupera o dBZ não negativo, sujeito à precisão float32. Não recupera o valor negativo original nem distingue um inválido de um zero sem consultar a máscara. A auditoria de 256 patches registrou erro máximo de aproximadamente $7{,}629 \times 10^{-6}$ na comparação com o cache clipado. [1]

O alvo não é log1p da refletividade linear Z nem taxa de chuva. dBZ já é uma representação logarítmica de refletividade. Somar esses valores ou chamá-los de volume de precipitação não fornece uma grandeza hidrológica válida sem conversão física e unidades explícitas.

5 Armazenamento e normalização

Array	Forma consolidada	Tipo no builder
input	(1.016.208, 12, 32, 32)	float32
target	(1.016.208, 1, 32, 32)	float32
mask	(1.016.208, 1, 32, 32)	float32
timestamps	(1.016.208,)	int64 em segundos Unix
patch_row e patch_col	(1.016.208,) cada	int16

O nome train.zarr é o nome do contêiner gerado. Na versão consolidada ele contém anos destinados a treino, validação e testes. Ler todo esse arquivo como treino violaria o protocolo: a seleção efetiva deve seguir os índices da divisão temporal formal. [1–3]

Escrita e metadados

O builder acumula patches em buffers e escreve lotes em arrays Zarr com compressão Blosc zstd. Registra canais, níveis, transformação do alvo, patch_size, stride e resolução nominal. Estatísticas, metadados e relatório de execução complementam os arrays. Chunk size e tamanho do lote são parâmetros de engenharia; não alteram a definição meteorológica da amostra. [3]

A documentação reprodutível deve conservar metadata.json, atributos do Zarr, normalization.npz, arquivos de estatísticas e execution_report.json. O relatório de execução registra configuração, contagens de rejeição, duração das etapas e erros. Esses registros permitem diferenciar um dataset incompleto de uma execução interrompida.

Duas estatísticas com papéis diferentes

O builder calcula médias e desvios ao longo dos exemplos que escreve. Se a execução cobre 2011–2024, essas estatísticas descrevem todo o período. Elas não podem ser usadas automaticamente como normalização de treinamento sem introduzir informação dos anos reservados. [3]

O protocolo formal exige recalcular média e desvio exclusivamente no split de treino, depois do purge, para os canais presentes no experimento. A mesma transformação é aplicada a validação e testes, sem novo ajuste. Canais derivados também precisam de estatísticas próprias calculadas apenas no treino. [2]

A implementação inspecionada usa pixels finitos para estatísticas da entrada e a máscara de validade para o alvo. Substitui desvio zero por um para evitar divisão por zero. A política efetiva do adaptador deve ser registrada e testada, inclusive a transformação inversa antes de métricas em dBZ.

Verificações mínimas de leitura

Conferir a ordem dos canais, dimensões, tipos, timestamps, máscara, offsets e transformação inversa. Uma tensorização que produz a forma correta mas troca canais ou normaliza com estatísticas erradas não preserva o contrato do dataset.

6 Características estatísticas e cobertura

A auditoria de referência encontrou 84.684 horários de 122.736 esperados, correspondentes a aproximadamente 69% de cobertura. Os 12 patches por horário resultam em 1.016.208 exemplos. O total de posições de alvo armazenadas é 1.040.596.992, incluindo repetição espacial por sobreposição. [1]

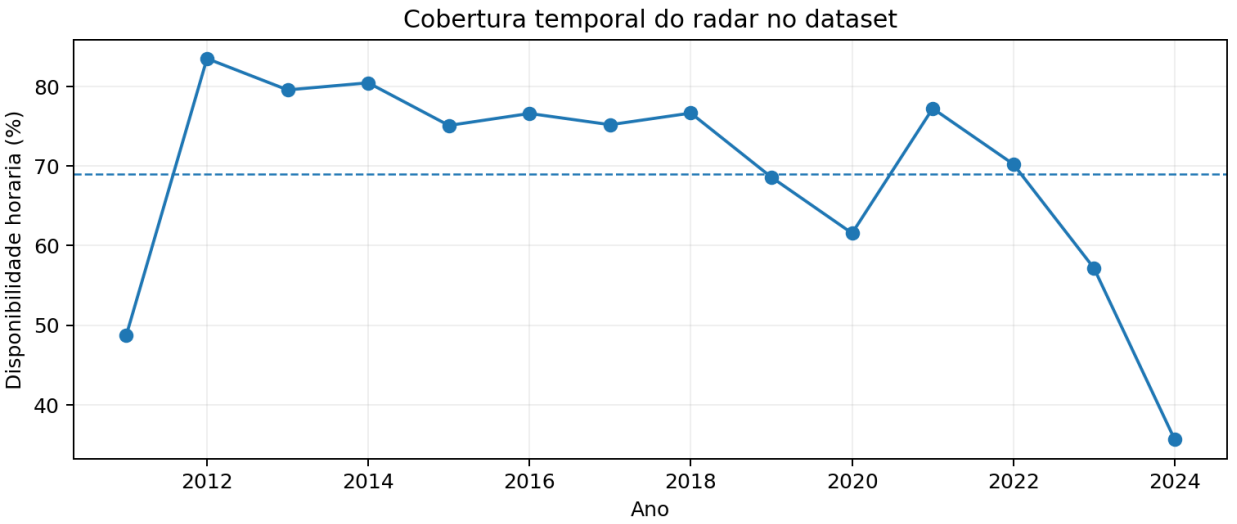


Figura 2 Cobertura anual documentada na análise de estabilidade temporal. [1, 4]

A disponibilidade cai para 57,15% em 2023 e 35,64% em 2024. A análise identificou grandes lacunas, incluindo 707 e 540 horas. Métricas desses anos descrevem os horários observados, e não uma amostragem anual uniforme. A perda de dados pode estar associada às condições meteorológicas ou à operação do sistema. [1]

Esparsidade e extremos

A caracterização documenta cerca de 98,53% de zeros entre pixels armazenados e 29,89% de patches com algum eco. As estatísticas univariadas iniciais usaram amostragem; as contagens de extremos abaixo foram reconciliadas na auditoria da Fase 4. [1]

Limiar	Pixels armazenados	Patches com evento
≥20 dBZ	15.077.040	29,76%
≥30 dBZ	5.253.244	16,08%
≥40 dBZ	1.372.827	7,60%
≥45 dBZ	727.939	2,82%
≥50 dBZ	163	71 patches

Esses números não são áreas geográficas deduplicadas. O limiar ≥50 dBZ é extremamente raro e não sustenta conclusões robustas sobre desempenho. Um modelo que produz apenas zeros pode ter erro médio aparentemente favorável e falhar em todos os eventos relevantes.

7 Dependências e informação meteorológica

Sazonalidade e ciclo diurno

As análises de timestamps mostram forte sazonalidade: ocorrência de ≥45 dBZ em aproximadamente 14,99% dos horários de DJF e 2,18% dos de JJA. O pico diurno de alta intensidade ocorre por volta de 13–14 h locais. Esses resultados são condicionados à disponibilidade e não devem ser confundidos com a frequência por patch. [1]

Persistência temporal

Para o limiar ≥45 dBZ, a probabilidade de evento após evento em t−1 h foi aproximadamente 0,638, contra 0,030 após ausência de evento; razão de risco perto de 21. Isso evidencia dependência temporal, não independência de exemplos consecutivos. A auditoria não encontrou repetição exata generalizada capaz de explicar a persistência, mas identificou sequências localizadas para controle de qualidade. [1]

Escalas espaciais

O primeiro lag amostrado com correlação do alvo inferior a 0,5 foi 16 km no eixo leste–oeste e 8 km no norte–sul. Esses valores dependem do método, das distâncias testadas e do suporte de patch; não definem diretamente o tamanho de uma célula convectiva. [1]

A decomposição Haar mostrou mais de 91% da energia espacial dos predictors em escalas nominais ≥32 km para praticamente todas as variáveis. O radar possui contribuição relevante em detalhes de 4–16 km. O ERA5 informa o ambiente do patch melhor do que a posição exata dos núcleos radar. Essa diferença fundamenta a hipótese de geração condicional de estrutura fina. [1]

Variáveis derivadas

Derivada	Definição
wind_speed_10, _850, _500	Norma sqrt(u² + v²) em cada nível
delta_t_500_850	t_500 − t_850
delta_t_850_surface	t_850 − t2m
delta_r_500_850	r_500 − r_850
bulk_wind_diff_10_850	Norma da diferença vetorial entre ventos
bulk_wind_diff_850_500	Norma da diferença vetorial entre níveis

As oito derivadas são funções determinísticas dos 12 canais raw. Podem facilitar representação e otimização, mas não acrescentam uma fonte meteorológica independente. Diferenças de temperatura não são, isoladamente, índices físicos de instabilidade; diferenças de vento em m/s não são cisalhamento normalizado pela distância vertical. [1, 2]

8 Protocolo de desenvolvimento e avaliação

A divisão formal é cronológica, com todos os patches de um mesmo timestamp no mesmo bloco e buffers de ±48 h nas fronteiras. A escolha reduz contaminação por janelas relacionadas e persistência temporal, mas não torna os sistemas meteorológicos independentes. [2]

Bloco	Período	Horários	Patches
Treino	2011–2020	63.587	763.044
Validação	2021–2022	12.828	153.936
Teste principal	2023	4.966	59.592
Stress e OOD	2024	3.108	37.296
Purge	Fronteiras	195	2.340
Total	2011–2024	84.684	1.016.208

Os totais de cada bloco são posteriores à exclusão de fronteiras. Portanto, não devem ser usados diretamente para recalcular a cobertura anual anterior ao purge. Normalização, ajuste e seleção são funções distintas: treino ajusta parâmetros, validação seleciona configurações e checkpoints, testes avaliam o desenho congelado.

Histórico exploratório e testes futuros

As Fases 0–14 já incluíram descrições e diagnósticos de 2023–2024, inclusive shift e resultados multivariados exploratórios. Logo, esses anos não podem ser apresentados como nunca examinados. O bloqueio posterior impede utilizá-los para selecionar os modelos CorrDiff; não apaga a exposição exploratória anterior. Essa distinção deve constar da dissertação. [1, 2]

Métricas adequadas à distribuição

O protocolo combina RMSE, MAE e bias em log1p e dBZ; métricas categóricas nos limiares 20, 30, 40 e 45 dBZ; FSS em suportes de 2, 4, 8 e 16 km; máximos de patch e estratificação por estação. Modelos probabilísticos exigem também calibração e avaliação de distribuição. [2]

Os baselines clássicos incluem zero, médias de treino, climatologia mês–hora–slot e persistência radar de uma hora. A persistência recebe radar passado e deve ser identificada como referência lateral, com avaliação em coorte comum quando necessária. Ela não possui as mesmas entradas do modelo ERA5-only. [2]

Relação com a Fase 18

A integração com o CorrDiff deve preservar canais, alvo, máscara, splits e normalização. Testes de leitura e execução curta verificam compatibilidade técnica. Não constituem evidência de skill nem substituem a campanha de treinamento, as ablações e a avaliação temporal final. A execução na máquina do CEFET permanece uma etapa operacional separada deste relatório.

9 Limitações e consequências científicas

Representação do radar e qualidade observacional

Reconstruir valores a partir de PNG limita a informação àquela preservada pelo produto gráfico. Quantização de cores, correspondência de paleta, recorte, georreferenciamento e mudanças de produto podem introduzir erros. A máscara isfinite detecta invalidez numérica, mas não atesta ausência de clutter, bloqueio, atenuação ou problemas de calibração. Esses são riscos a investigar, não defeitos comprovados em todos os exemplos. [3]

O clipping de valores negativos e o preenchimento são transformações irreversíveis sem o cache original e a máscara. Um pixel válido igual a zero no alvo não permite distinguir todas as situações físicas que levaram a esse zero. Contagens de zeros, por isso, são propriedades da representação processada.

Ausência temporal e mudança de distribuição

A cobertura incompleta limita climatologias, comparações interanuais e estimativas de risco. Se a ausência não for aleatória, normalizar apenas pelo número de horários disponíveis não elimina o viés. A avaliação deve apresentar disponibilidade por ano, mês, estação e coorte de análise, particularmente em 2024.

A Fase 14 encontrou mudanças dos predictors, da composição dos regimes e da disponibilidade. Não encontrou evidência robusta de ruptura condicional generalizada. Atribuir toda diferença a mudança climática, a falha de radar ou a concept drift extrapolaria os resultados documentados. [1]

Dependência e suporte espacial

Patches se sobrepõem, horários próximos compartilham sistemas e o ERA5 interpolado é suave. O tamanho amostral efetivo é inferior ao número bruto de patches e pixels. Intervalos de confiança ou testes estatísticos devem respeitar agrupamentos temporais e espaciais; reamostragem independente de pixels tende a subestimar incerteza.

A janela limita o contexto espacial a aproximadamente 64 km por lado. Estruturas maiores podem ser truncadas, núcleos podem tocar bordas e a geração independente pode produzir descontinuidades entre patches. Reconstrução em mosaico requer política de combinação das sobreposições e auditoria dos offsets.

Raridade e alcance das conclusões

Extremos são raros e sujeitos a alta variância de avaliação. É necessário informar suporte amostral, evitar seleção por uma única seed e distinguir ganho global de preservação dos núcleos intensos. Associação entre ERA5 e radar não prova causalidade; bom ranking exploratório não demonstra calibração nem habilidade do CorrDiff. [1, 2]

O dataset sustenta estudo retrospectivo regional. Validade operacional, transferência geográfica e benefício para previsão futura dependem de novos experimentos com fontes, latências e horizontes explicitamente definidos.

10 Rastreabilidade e condições de reprodução

Registrar a identidade do conjunto

Cada versão deve conservar período solicitado, horários aceitos, domínio, grade, ordem e unidade dos canais, resolução nominal, patch_size, stride, thresholds de validade, transformação do radar e versões dos códigos. Hashes dos manifestos e artefatos ajudam a identificar alterações de conteúdo sem depender somente do nome train.zarr.

Separar construção de experimento

Preservar os dados processados e seus metadados de construção. Em uma camada experimental própria, conservar índices dos splits, purge, estatísticas train-only, canais de cada ablação, seeds e configuração de avaliação. Mudanças em qualquer uma dessas definições exigem nova identificação de versão e análise de comparabilidade.

Conferir a cadeia antes do treinamento

Validar a leitura do Zarr, a ordem raw12, a correspondência timestamp–patch, a máscara e a inversão do alvo. Confrontar uma amostra com o cache radar; verificar a inexistência de interseção entre splits; conferir que estatísticas não usam validação ou testes. Registrar exemplos rejeitados e distinguir corrupção de arquivo de ausência real da observação.

Na avaliação, informar se o denominador é pixel, patch ou timestamp; se as contagens incluem sobreposição; qual coorte possui lags completos; e se a métrica é em log1p ou dBZ. Não converter frequência amostral em climatologia regional sem explicitar essas escolhas.

Referências e materiais do projeto

[1] Relatório Técnico Científico Consolidado CorrDiff ERA5 para Radar Sumaré, Fases 0 a 14. Atualização de 20 de setembro de 2026. Arquivo Relatorio_CorrDiff_Fases_0_a_14.docx. Fonte dos totais, auditoria, caracterização, dependências e shift.

[2] CorrDiff Fases 15 16 17. Arquivo CorrDiff_Fases_15_16_17.docx. Fonte do split formal, protocolo de métricas, baselines clássicos e desenho das ablações.

[3] AILAB CEFET RJ. RioNowcastDF. Código src/corrdiff/builder/dataset_builder.py, revisão cd2f81719df80a08726c2840d14ec7f1d83c3579. https://github.com/AILAB-CEFET-RJ/rionowcastdf/blob/cd2f81719df80a08726c2840d14ec7f1d83c3579/src/corrdiff/builder/dataset_builder.py

[4] Figuras e apresentação técnica do projeto. Apresentacao_CorrDiff_Fases_0_a_17_Validada e imagens builder_fig1_clean.png e figura de cobertura extraída do relatório consolidado. As figuras ilustram resultados e procedimentos documentados; desenhos esquemáticos não substituem metadados executáveis.

Acervo de imagens

O pacote de imagens mantém as figuras recuperadas, organizadas por origem e finalidade, com inventário de arquivos e indicação de versões históricas. Esquemas antigos podem conter configurações, nomes de etapas ou status diferentes do protocolo consolidado. Para valores técnicos, prevalecem o contrato do dataset, o relatório correspondente à versão e os artefatos de execução.