CorrDiff Rio Nowcast DF

Estruturação do dataset, principais características, potenciais, limitações e protocolo experimental (Fases 0–17)



Apresentação consolidada para orientação acadêmica

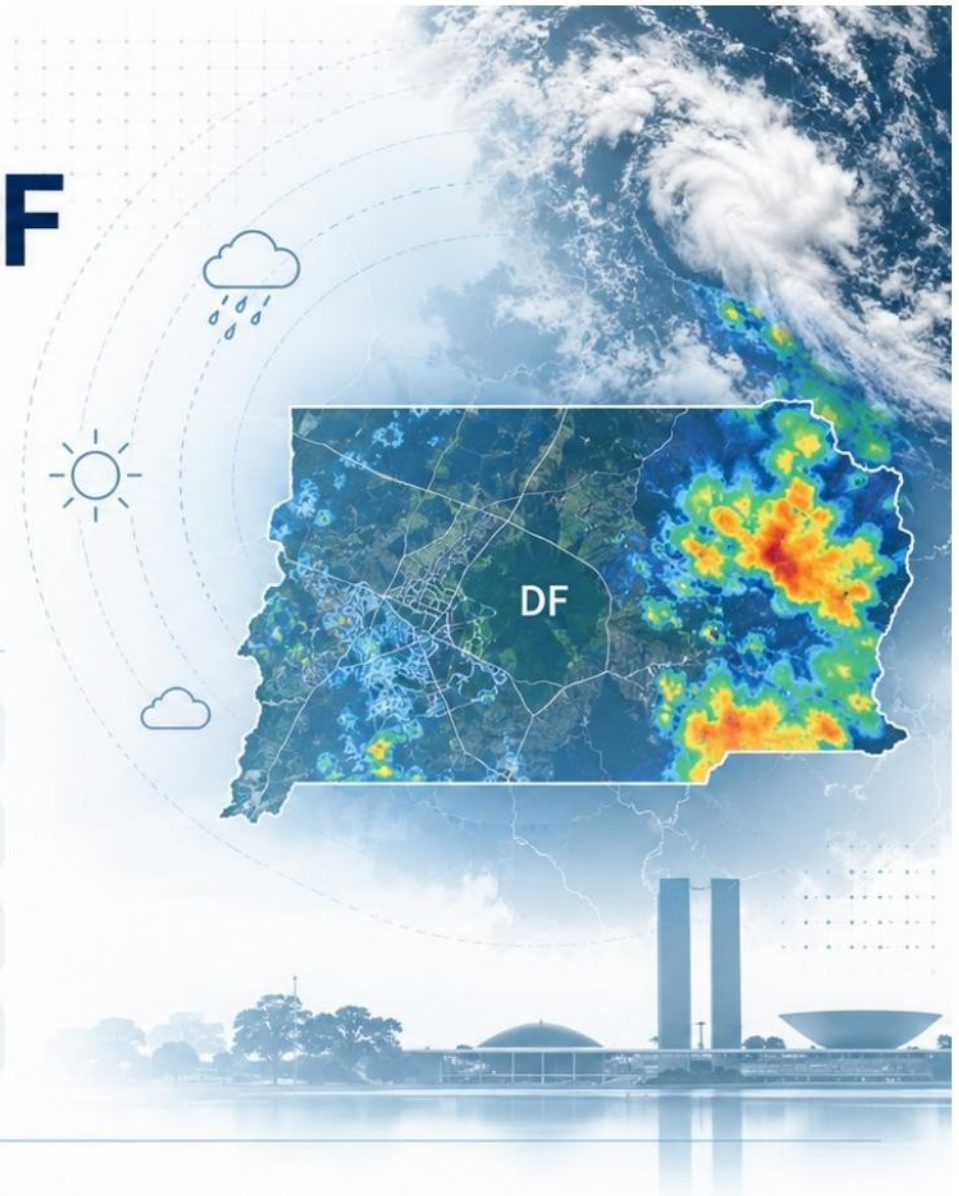
CorrDiff Rio Nowcast DF

Dataset, características, limitações e protocolo experimental

SÍNTESE DAS FASES 0–17

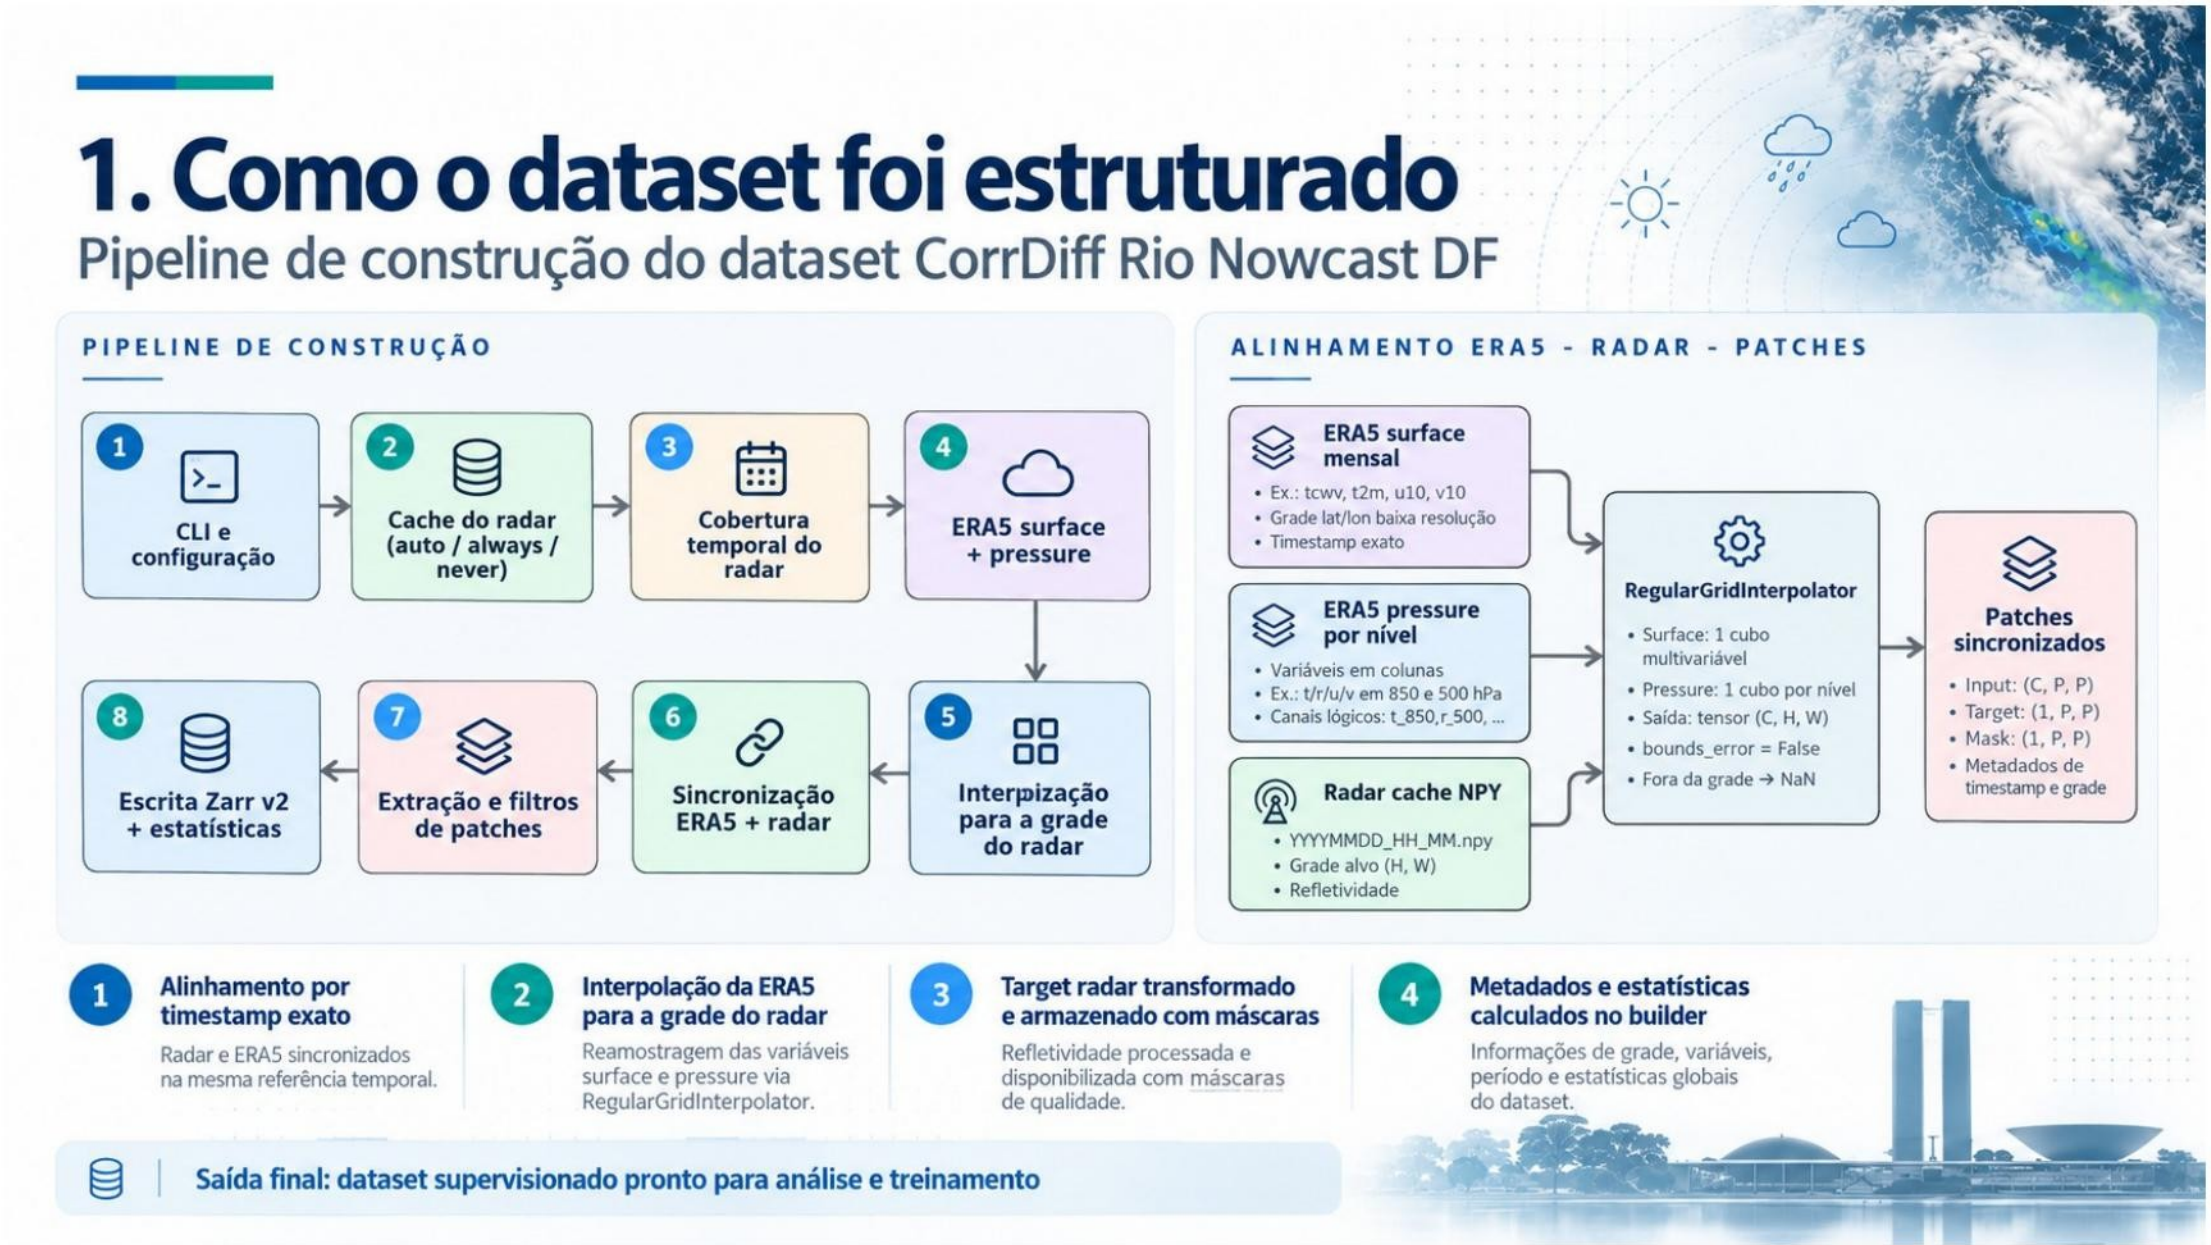
AGENDA

1. Como o dataset foi estruturado
2. Principais características, potencíais e limitações
3. Resultados analíticos das fases
4. Protocolo experimental para os experimentos CorrDiff



Baseado nas análises e relatórios detalhados das fases 0 a 17

2. Pipeline do dataset CorrDiff Rio Nowcast DF e alinhamento entre ERA5 e radar



3. Estrutura do dataset e mecanismo de criação dos patches

1. Estrutura final do dataset e criação dos patches

Canais preditores, target e mecanismo de patchificação

Entradas e saídas

Preditores (12 canais)	tcwv, t2m, u10, v10, t_850, r_850, u_850, v_850, t_500, r_500, u_500, v_500
Target	refletividade do radar
Transformação	domínio armazenado em log1p e reconstrução em dBZ
Patch	32 × 32
Unidade	1 patch por amostra
Estrutura	input (C,P,P), target (1,P,P), máscara (1,P,P)

radar_read
Leitura NPY por timestamp

→

patch_processing
Geração de patches com janelas deslizantes + filtros

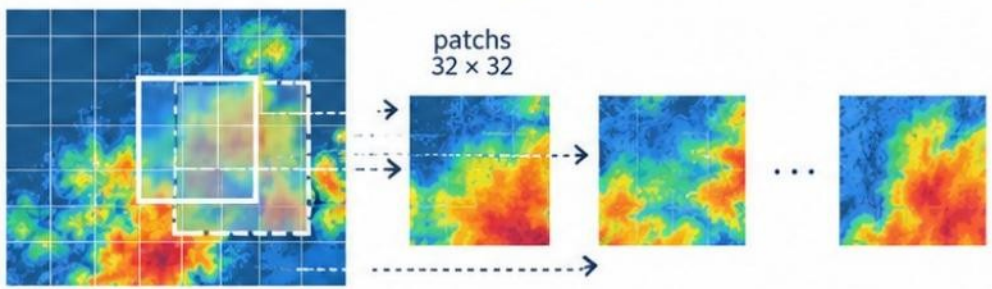
→

zarr_flush
Empilhamento, resize e escrita comprimida

→

statistics
Normalização e metadados

janelas deslizantes com sobreposição



Implicação analítica

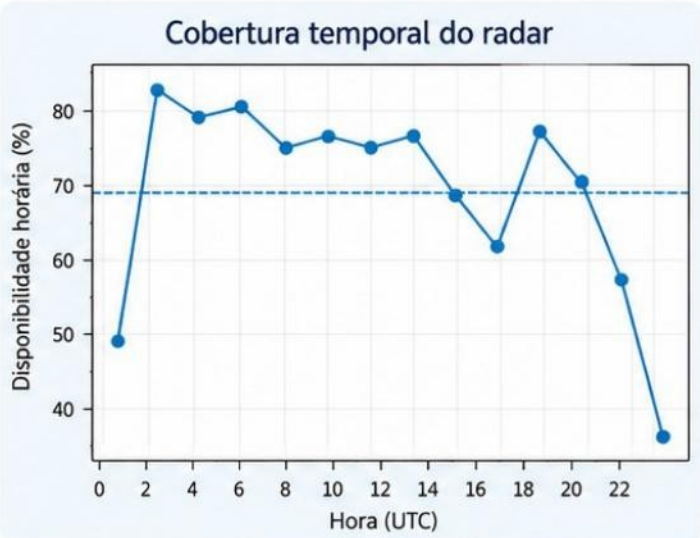
1. Sobreposição aumenta o número de amostras
2. Patchs vizinhos não são independentes
3. A avaliação precisa respeitar splits temporais e coortes

4. Principais características, potenciais e limitações metodológicas dos dados

2. Principais características, potenciais e limitações

O que o dataset oferece e quais cuidados metodológicos ele exige

Característica	Potencial	Limitação/risco
1 Combinação ERA5 + radar	Integra condições de grande escala (ERA5) com a estrutura de mesoescala e convecção (radar).	Diferenças de resolução espacial, características físicas e eventuais desalinhamentos espaço-temporais.
2 12 canais multivariados	Representa múltiplos aspectos dinâmicos, termodinâmicos e de precipitação, favorecendo modelos multitarefa e baseados em deep learning.	Variáveis com escalas e distribuições distintas; necessidade de normalização e seleção de variáveis.
3 Cobertura horária variável do radar	Longa série temporal (2011–2024) com alta disponibilidade média de dados, permitindo análises climatológicas e sazonais.	Cobertura não uniforme no tempo, com quedas de disponibilidade em alguns períodos (ex.: < 50%).
4 Patchificação com sobreposição	Aumenta o número de amostras, preserva o contexto espacial e melhora a aprendizagem de padrões locais.	Amostras vizinhas são correlacionadas, podendo causar vazamento de informação se a separação temporal não for rigorosa.
5 Forte assimetria dos extremos convectivos	Representa realisticamente a baixa frequência de eventos intensos, essencial para estudos de nowcasting e riscos.	Desbalanceamento severo entre casos sem e com convecção intensa, exigindo estratégias específicas de treeino, avaliação e métricas.
6 Não estacionariedade temporal (2011–2024)	Permite investigar mudanças em regimes meteorológicos e desempenho em diferentes anos e estações.	Mudanças em instrumentação, cobertura, processamento e clima podem afetar a consistência temporal e a generalização dos modelos.





Síntese

1. Bom potencial para nowcasting condicional.
2. Dataset rico para estudos de extremos e regimes.
3. Necessidade de protocolo temporal rigoroso.
4. Avaliar separadamente habilidade global e extremos.

Baseado nas análises e relatórios detalhados das fases 0 a 17

Fase 0 — qualidade e integridade do dataset

Antes de qualquer interpretação meteorológica, shapes, máscara, timestamps e semântica do target foram auditados

1.016.208
patches alinhados
shape input: [N,12,32,32]

84.684
timestamps disponíveis
de 122.736 esperados

69,00%
cobertura temporal global
38.052 horários ausentes

PASS
auditoria cache → target
erro máx. expm1 ≈ $7{,}63 \times 10^{-6}$

Cobertura observada

Primeiro timestamp disponível	**2011-01-17 19 UTC**
Último timestamp disponível	**2024-12-31 23 UTC**
Pixels válidos armazenados	**1.040.596.992 (100%)**

Conclusão da Fase 0

O dataset é estruturalmente consistente. A principal limitação não é de shape ou máscara, mas de cobertura temporal incompleta e heterogênea — aspecto que se torna crítico em 2023–2024.

Fonte: Relatório Consolidado Fases 0–14, Seção 2.1.

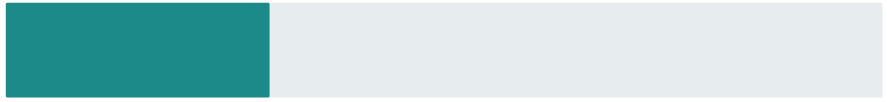
Fase 1 — sparsidade extrema do radar

Boa média numérica pode ser enganosa quando quase todos os pixels estão secos

Em nível de pixel

1,47% > 0 — 98,53% = 0

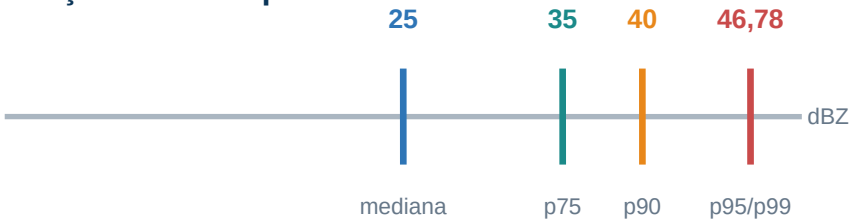
Em nível de patch



29,89% com eco — 70,11% sem eco

Amostra analítica: 32.768 patches

Distribuição dos dBZ positivos



Implicação para treino e avaliação

Perdas e métricas dominadas por pixels secos podem parecer boas mesmo quando o modelo não representa ocorrência, intensidade ou extremos. Por isso as fases seguintes passam a separar explicitamente esses três aspectos.

Fonte: Relatório Consolidado Fases 0–14, Seção 2.2.

Fase 2 — variáveis raw, derivadas e redundância

As derivadas ajudam a representar estrutura vertical e vento, mas não adicionam informação meteorológica independente

Moisture

tcwv • r_850 • r_500

Thermal

t2m • t_850 • t_500

Dynamics

u10 • v10 • u_850 • v_850 • u_500 • v_500

8 variáveis derivadas

wind_speed_10
wind_speed_850
wind_speed_500
delta_t_500_850
delta_t_850_surface
delta_r_500_850
bulk_wind_diff_10_850
bulk_wind_diff_850_500

Cuidados de interpretação

- Derived = transformação determinística dos raw.
- delta_t é diferença de temperatura; não rotular automaticamente como “instabilidade”.
- bulk_wind_diff é diferença vetorial em m/s; não é shear normalizado por altura.

Fonte: Relatório Consolidado Fases 0–14, Seção 2.3; Fase 17 para a organização por famílias.

Fases 3–4 — associação ERA5–radar e extremos

O sinal muda com a severidade: umidade domina eventos moderados; térmica/dinâmica ganha importância relativa na cauda

≥20	r500	+0,96	tcwv	+0,92			umidade
≥30	tcwv	+0,56	t850	+0,55			transição
≥40	t850	+0,73	t500	+0,68	ws10	−0,66	térmica + dinâmica
≥45	t500	+0,82	ws10	−0,79	t850	+0,73	extremos

Fase 3

As correlações pixelwise globais são pequenas; os principais sinais estão associados a ocorrência e ambiente.

Fase 4

Ao elevar o threshold, a assinatura meteorológica muda. r500 chega a inverter sinal em extremos — comportamento não monotônico/regime-dependente.

≥50 dBZ: 163 pixels / 71 patches — cauda ultra-rara; útil para auditoria, não para conclusões robustas isoladas.

Fonte: Relatório Consolidado Fases 0–14; Fase 4 v3.1. Valores abaixo são SMDs representativos documentados.

Fases 5–6 — sazonalidade e ciclo diurno

A probabilidade de eventos intensos depende fortemente da estação e da hora local

14,99%

eventos ≥45 em DJF

taxa por timestamp

2,18%

eventos ≥45 em JJA

taxa por timestamp

13–14 h

pico local de eventos intensos

razão pico/vale ~13,2 em ≥45

Leitura científica

- Eventos extremos não são temporalmente uniformes.
- Estação e hora local precisam aparecer em análises e métricas.
- Missingness temporal pode se combinar com a sazonalidade.

Cuidado com delta_t_850_surface

t850 − t2m fica mais negativo com o aquecimento diurno da superfície. Esse comportamento é consistente com o ciclo diário, mas não deve ser rotulado automaticamente como “instabilidade”.

Fonte: Relatório Consolidado Fases 0–14, Fases 5–6 e Apêndice A.

Fases 7–8 — memória temporal real, mas estrutura espacial evolui

Persistência agregada é forte; a auditoria mostra que não se trata de duplicação generalizada do target

73.977
pares exatos com lag 1 h
coverage temporal da Fase 7

~21,1×
RR de persistência em 1 h (≥45)
P(evento|prev)=0,638 vs 0,030

0,283
BSS logística temporal (≥45)
Brier=0,0440 | AP=0,545

0,097
BSS persistência 1 h
referência observacional

Skill em ≥45 dBZ



A logística usa múltiplos lags; esta coorte é condicionada por disponibilidade temporal e não é climatologia global.

Auditoria de continuidade

0,244% pares any_wet com target completo exatamente igual

5,37% pares relevantes com fração ≥45 exatamente igual

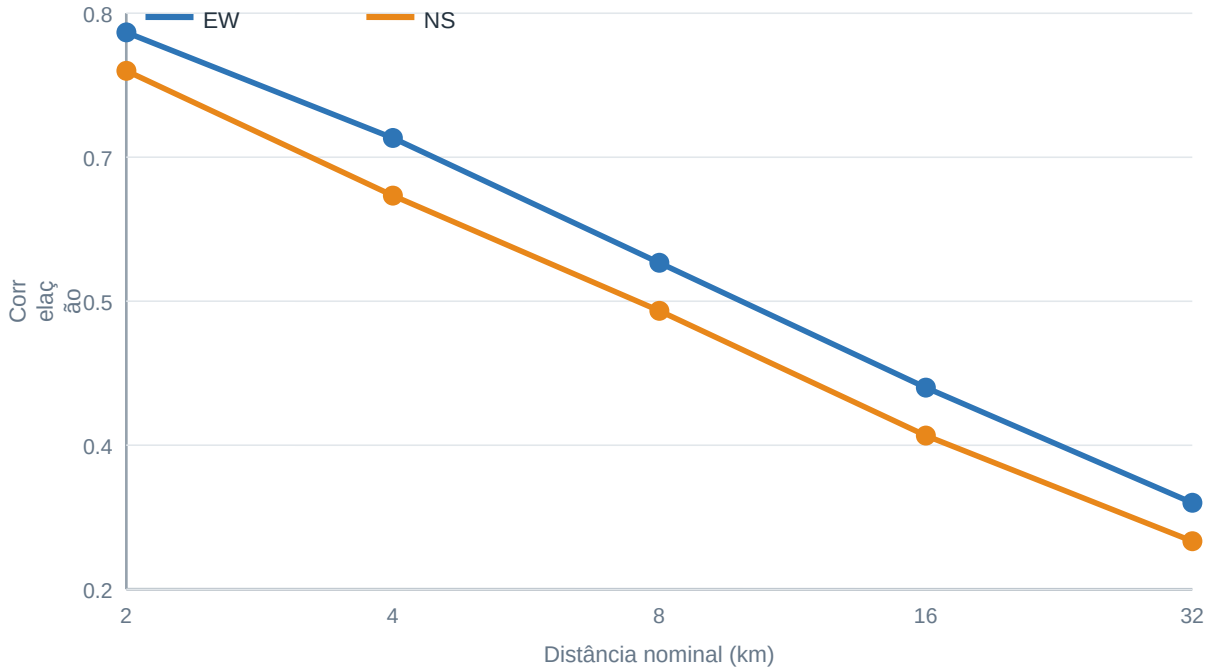
Conclusão: intensidade e extensão têm memória; a realização espacial fina continua evoluindo.

Fonte: Relatório Consolidado Fases 0–14; Relatório Especializado Fase 8.

Fase 9 — estrutura espacial própria do radar

A refletividade apresenta coerência espacial forte em pequena escala e anisotropia estatística EW > NS

Correlação espacial do target log1p



Primeiro lag medido com r < 0,5: EW 16 km | NS 8 km | diagonal ~11,3 km

O que a Fase 9 demonstra

- O radar tem organização espacial; não é ruído branco.
- EW permanece acima de NS em todos os lags medidos — anisotropia estatística, sem inferir causa física.
- Com o aumento do threshold, os núcleos tendem a ficar mais compactos/coerentes dentro do patch.
- Patch 32×32 limita a maior escala analisável e sofre efeitos de borda.

Implicação

Métricas espaciais por escala, como FSS, são mais adequadas que erro pontual isolado.

Fonte: Relatório Especializado Fase 9. Valores do gráfico são leituras aproximadas da curva consolidada.

Fase 10 — ERA5 informa melhor o ambiente do que a localização fina

A associação cresce quando agregamos o patch; pixelwise e cross-offset permanecem muito fracos

Associação local / pixelwise



Após centralização intra-patch: |r| tipicamente ~0,01–0,02

Cross-offset: melhores |r| em geral ≤ 0,02 — a baixa localização não é explicada por um deslocamento fixo simples.

Associação em nível de patch com max_dbz



Contraste evento–background em ≥45

t2m e r850 maiores; wind_speed_10 menor; delta_t_850_surface mais negativo; bulk_wind_diff_10_850 menor.

Leitura: há sinal meteorológico local, mas insuficiente para determinar coordenadas de núcleos convectivos.

Fonte: Relatório Especializado Fase 10; Relatório Consolidado Fases 0–14, Seção 2.11.

Fase 11 — separação formal de escalas

ERA5 e radar carregam variabilidade predominantemente em suportes diferentes

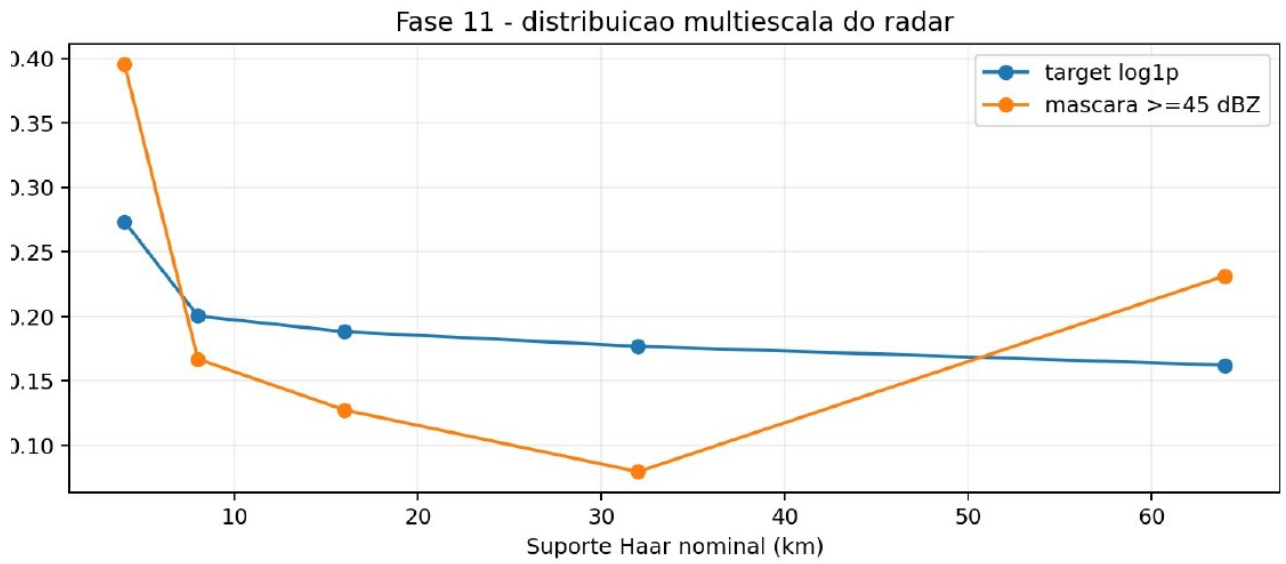


Figura original: energia Haar do target e da máscara ≥45 em suportes nominais 4, 8, 16, 32 e 64 km.

Resultados centrais

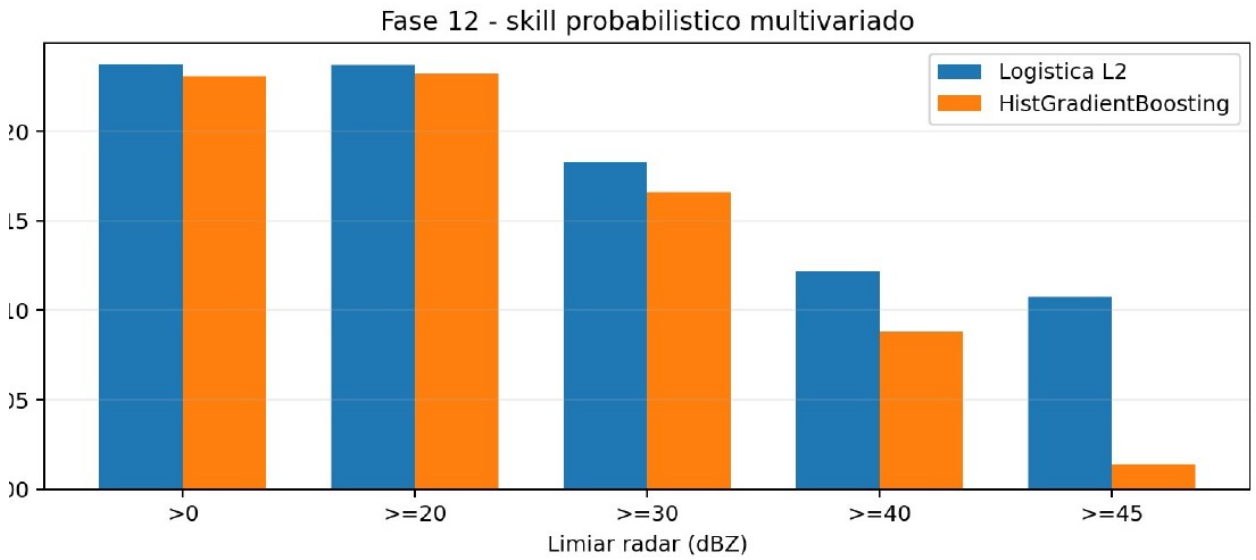
- Predictors ERA5: >91% da energia em suportes ≥32 km.
- Radar: energia distribuída; parcela importante em 4–16 km.
- Máscara ≥45 concentra grande energia em pequena escala.
- Correlação Haar ERA5–radar ~0 em 4–8 km; cresce apenas modestamente em escalas maiores.
- Coarse graining aumenta a associação, sobretudo em 16–32 km.

Conclusão: o CorrDiff precisa sintetizar variabilidade espacial que não está resolvida de forma independente no conditioning ERA5.

Fonte: Relatório Consolidado Fases 0–14, Figura 4; Relatório Especializado Fase 11.

Fase 12 — existe sinal multivariado no ERA5

O conditioning é útil para estado ambiental e intensidade potencial; maior complexidade não garante melhor calibração



BSS médio: ~0,237 em >0/≥20 → ~0,107 em ≥45 | ROC AUC: ~0,77 → ~0,87

Os valores intermediários do gráfico são leituras aproximadas da figura consolidada.

10
PCs para 90% da variância

12
PCs para 95% da variância

Condition number ≈ 76,1

Desenho experimental

- 16.273 patches estratificados.
- means_only (20) vs means_plus_std (40).
- 5 folds forward-chaining: passado → futuro.

Leitura por famílias

Moisture domina eventos moderados; thermal ganha importância relativa em ≥40/≥45. Dynamics não é descartada.

Fonte: Relatório Consolidado Fases 0–14, Figura 5; Relatório Especializado Fase 12.

Fase 13 — regimes meteorológicos recorrentes

Clusters definidos somente pelo ERA5; o radar entra depois para medir enrichment e persistência

Enriquecimento no regime R5 — espaço absoluto



Absolute R5: taxa ≥45 ≈ 16,17% | RR ≈ 2,03

Anomaly R4: taxa ≥45 ≈ 14,03% | RR ≈ 1,76

Extremos aparecem em mais de um tipo de ambiente favorável.

k=5
resolução descritiva de referência
silhouette maior em k=3

7
PCs para ~90% da variância
absolute e anomaly

Estabilidade entre seeds

ARI absolute ~0,995
ARI anomaly ~0,988

Persistência 1 h dos regimes

~0,92–0,96

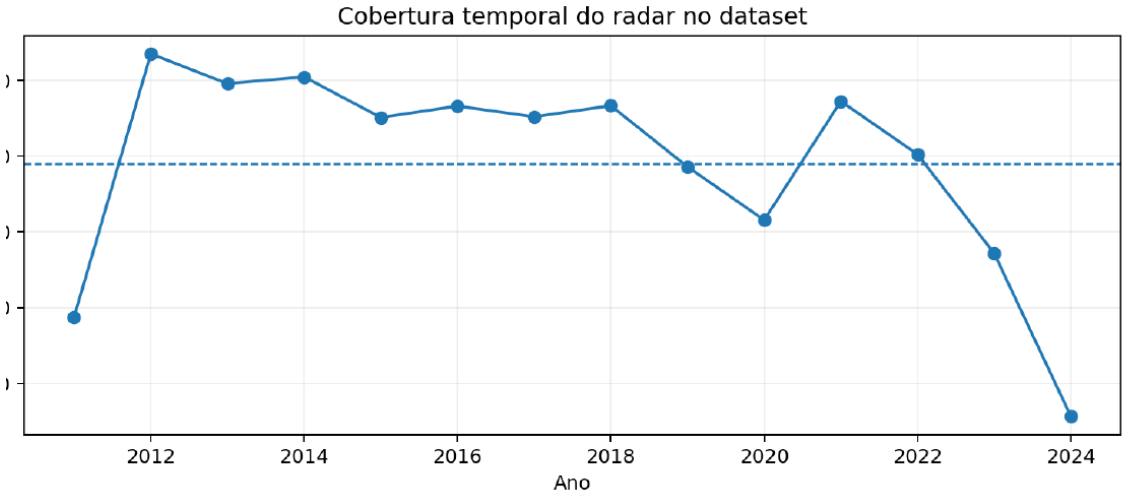
Cuidado terminológico

R1–R5 são estados estatísticos em PCA/KMeans — não classes meteorológicas físicas rígidas.

Fonte: Relatório Especializado Fases 13–14; Relatório Consolidado Fases 0–14.

Fase 14 — distribution shift e estabilidade temporal

2023–2024 combinam queda de coverage, covariate shift e mudança na composição dos regimes



2023: 57,15% | 2024: 35,64% — 2024 é amostra temporal altamente selecionada

Linha tracejada da figura original: cobertura global ~69%.

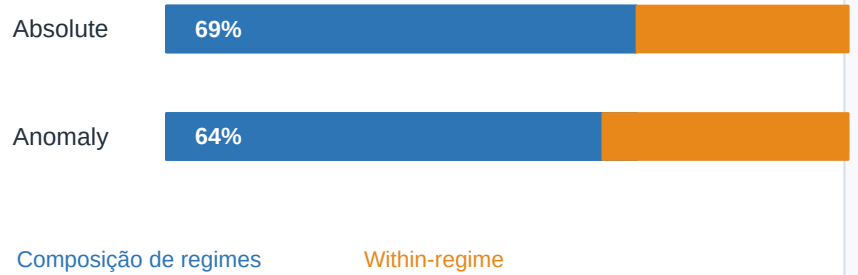
Covariate shift

t500: SMD abs ~0,348 | anomaly ~0,388
tcwv: ~0,198 | ~0,234
2024 t500: SMD ~0,648 | PSI ~0,436

Mudança de composição

TV absolute ~0,073 | anomaly ~0,088
R5 abs +5,14 pp | R2 −6,37 pp | R4 anomaly +6,90 pp

Decomposição da mudança em ≥45

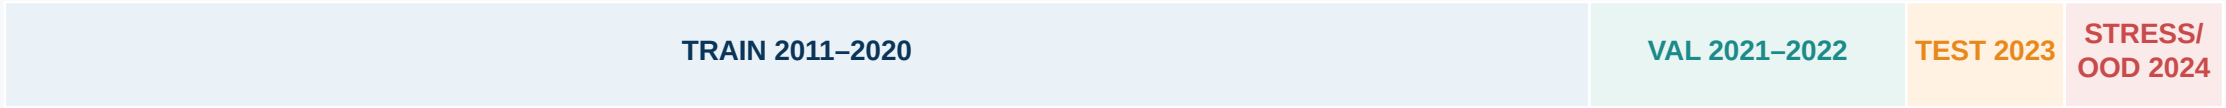


≥45: 7,84% → 9,12%, mas o IC bootstrap da diferença inclui zero. Evidência de concept drift amplo permaneceu fraca.

Fonte: Relatório Consolidado Fases 0–14, Figuras 7–8; Relatório Especializado Fases 13–14.

Fase 15 — split temporal formal e governança contra leakage

O desenho experimental foi congelado antes do treinamento: aprender no passado, selecionar no futuro próximo e preservar testes reais



purge ±48 h nas fronteiras

63.587
timestamps train
763.044 patches

12.828
timestamps validation
153.936 patches

4.966
timestamps test 2023
59.592 patches

3.108
timestamps stress 2024
37.296 patches

✓ **Todos os 12 patches de um timestamp ficam no mesmo split** — Evita leakage espacial/meteorológico.

✓ **Normalização e transforms data-dependent: train-only** — Evita informação futura no preprocessing.

✓ **Sem estratificação por target** — Preserva mudanças reais de distribuição.

✓ **2023 e 2024 bloqueados durante desenvolvimento** — 2024 nunca compõe o headline de 2023.

Fonte: Relatório Especializado Fases 15–17.

Fase 16 — baselines clássicos: o piso que o CorrDiff precisa superar

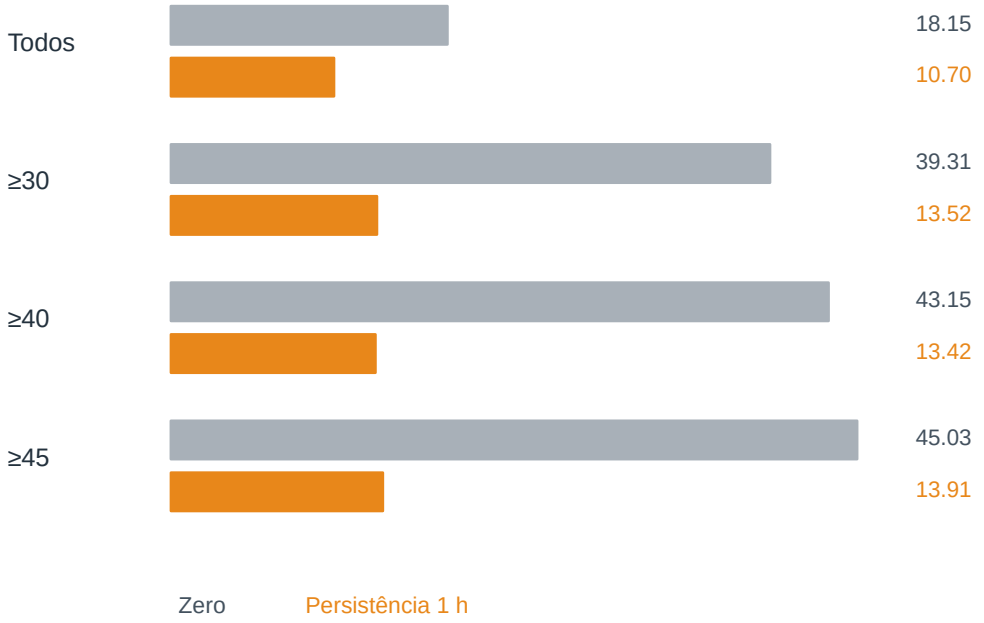
Médias melhoram levemente RMSE, mas falham completamente nos extremos; persistência preserva intensidade, não posição

RMSE global em log1p — validation



Climatologias médias: POD = CSI = FSS = 0 para ≥30 / ≥40 / ≥45 dBZ.

RMSE do máximo por patch — zero vs persistência 1 h



Em ≥45: CSI ~0,0034 | POD ~0,0063 | FAR ~0,993 — forte intensidade, baixíssima coincidência pixel a pixel.

Fonte: Fase 16 v2.2 — validation e persistence_common; Relatório Especializado Fases 15–17.

Fase 16 — protocolo de métricas e handoff NVIDIA

O objetivo não é otimizar um único score, mas medir erro, evento, espaço, extremos e robustez sazonal

Família	Métricas / suportes	Por que
Pontual	RMSE, MAE, bias em log1p e dBZ	erro médio e viés
Categórica	20/30/40/45 dBZ: POD, FAR, CSI, ETS, F1, freq. bias	eventos raros
Espacial	FSS em 2, 4, 8 e 16 km	deslocamento e organização
Extremos	max por patch: todos, ≥30, ≥40, ≥45	intensidade / suavização
Sazonal	DJF / MAM / JJA / SON	skill dependente da estação

Auditoria v2.2

73.977 timestamps com lag exato de 1 h

138.600 / 153.936

patches na validation em persistence_common (~90%)

O manifesto temporal da Fase 15 passou a ser a fonte autoritativa de calendário.

Handoff NVIDIA: índices por split + normalização train-only + contrato do dataset + thresholds + protocolo de métricas. A integração posterior não pode alterar silenciosamente canais, target ou avaliação.

Fonte: README_PHASE16 / Relatório Especializado Fases 15–17.

Fase 17 — desenho formal das ablações de conditioning

A fase não treina modelos: ela pré-registra as comparações que serão executadas no ambiente NVIDIA CorrDiff

ID	Configuração	Categoria
C00	raw12	referência
C01	moisture only	suficiência
C02	thermal only	suficiência
C03	dynamics only	suficiência
C04	no dynamics	necessidade
C05	no thermal	necessidade
C06	no moisture	necessidade
C07	raw12 + all derived	representação
C08	raw12 + moisture derived	representação
C09	raw12 + thermal derived	representação
C10	raw12 + dynamics derived	representação

Perguntas científicas diferentes

Suficiência — C01–C03: quanto cada família explica sozinha?

Necessidade — C00 vs C04/C05/C06: o que se perde ao remover uma família?

Representação — C00 vs C07–C10: derived facilitam o aprendizado sem adicionar informação nova?

Campanhas pré-registradas

Stage R — regression nativo — **11 experimentos × 3 seeds = 33 runs**

Stage D — CorrDiff confirmatório

C00, C04, C05, C06, C07 × 3 = 15 runs obrigatórios

Seeds fixas: 42, 43, 44 | 2023/2024 continuam bloqueados

Fonte: Relatório Especializado Fases 15–17; contrato de ablações da Fase 17.

Síntese científica — por que CorrDiff é coerente com os dados?

As Fases 0–17 convergem para uma separação entre ambiente previsível e realização espacial fina

ERA5 conditioning

- Regimes e contexto ambiental.
- Umidade → ocorrência/moderados.
- Térmica ganha importância em extremos.
- Alta persistência de estado ambiental.
- Pouca localização fina pixel a pixel.

Regression model

- Componente média / previsível.
- Intensidade potencial e estrutura ampla.
- Deve superar climatologias sem “apagar” extremos.

CorrDiff generativo

- Variabilidade espacial fina.
- Localização plausível de núcleos.
- Estrutura 4–16 km.
- Extremos e incerteza condicional.

Evidência-chave: ERA5 tem sinal ambiental e multivariado real, mas não resolve independentemente a estrutura espacial fina que o radar contém. Isso torna P(Radar | ERA5) plausivelmente multimodal.

Síntese derivada exclusivamente dos resultados documentados das Fases 0–17.

Potenciais e limitações do dataset

O valor científico do dataset está diretamente ligado a conhecer e preservar suas restrições

Potenciais

- Série longa 2011–2024 com pares ERA5–radar alinhados.
- 12 canais raw fisicamente interpretáveis em superfície, 850 e 500 hPa.
- Mais de 1 milhão de patches e 84 mil timestamps disponíveis.
- Radar possui estrutura espacial real em múltiplas escalas — alvo apropriado para downscaling generativo.
- Sinal ERA5 multivariado positivo, regimes estáveis e hipóteses de ablação pré-registradas.
- Protocolos de split, normalização, baselines e métricas já congelados.

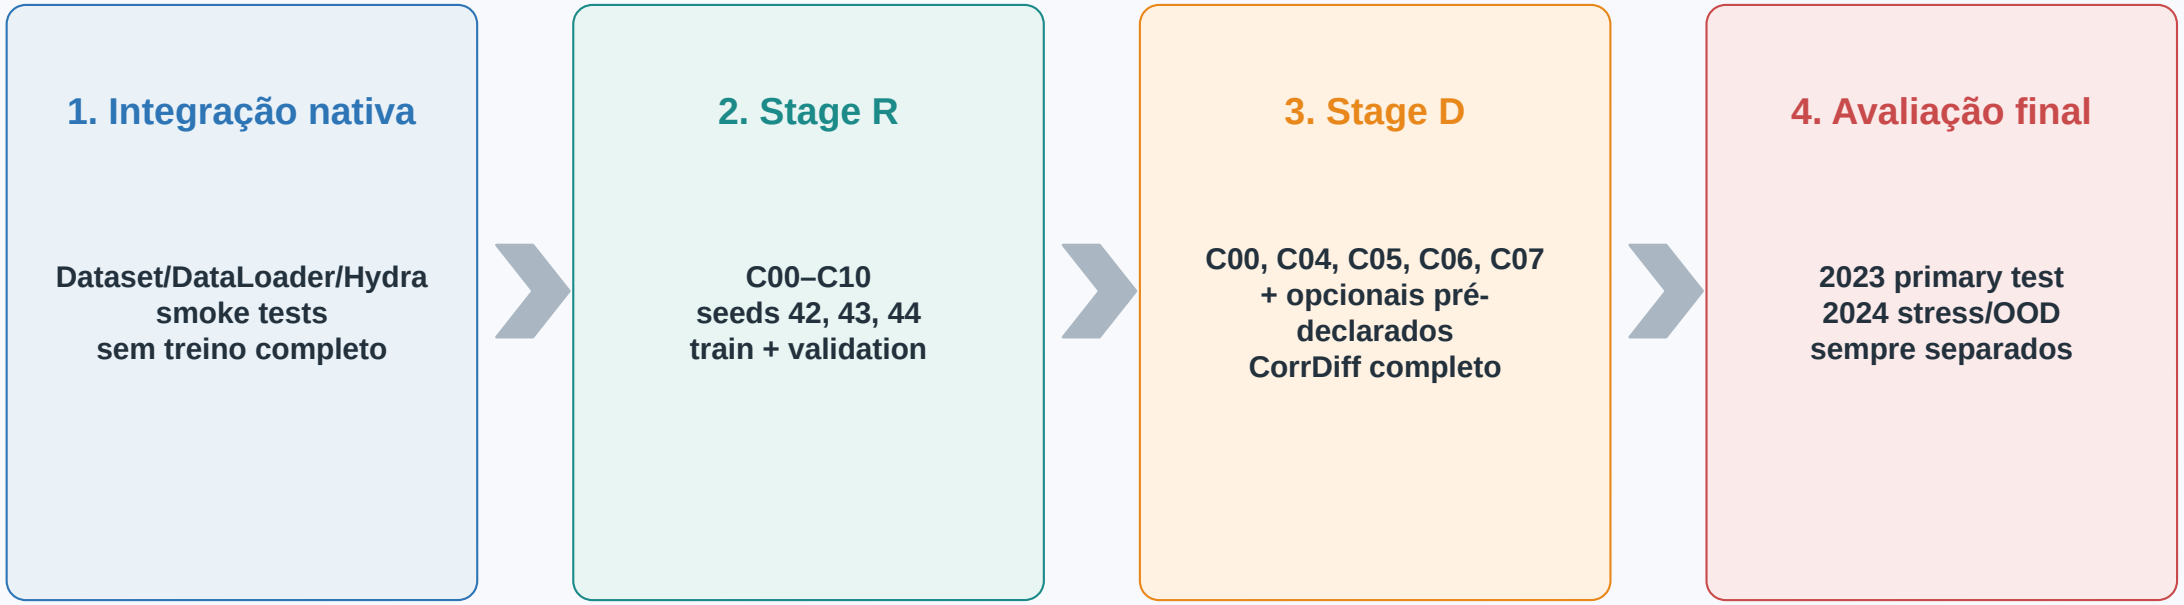
Limitações / cuidados

- Cobertura radar incompleta e heterogênea; missingness pode não ser aleatório.
- Patches sobrepostos repetem pixels/estruturas e não são amostras IID.
- ERA5 remapeado para ~2 km não ganha resolução física independente.
- Target clipa dBZ negativos e aplica log1p: semântica deve permanecer explícita.
- Análises espaciais são patch-based e sensíveis a bordas / truncamento.
- ≥45 e especialmente ≥50 têm incerteza maior por raridade.
- 2024 combina forte shift com coverage de apenas 35,64% — usar como stress/OOD.
- Resultados são descritivos/preditivos, não causais.

Fonte: Relatório Consolidado Fases 0–14, Seção de limitações; Fases 15–17.

Próximo passo — iniciar os experimentos sem romper o protocolo

A partir daqui, o foco deixa de ser diagnóstico do dataset e passa para integração e treinamento nativo NVIDIA



Princípio preservado: nenhuma decisão de arquitetura, conditioning, loss, checkpoint ou hiperparâmetro deve usar 2023/2024 antes do design freeze.

Mensagem para a orientação: o projeto chega ao treinamento com hipóteses, baselines, métricas, splits e riscos do dataset já explicitados — o ganho do CorrDiff poderá ser interpretado de forma auditável.

Base: contrato experimental congelado nas Fases 15–17.