CORRDIFF

Relatório Especializado - Fases 0 a 4

Integridade do dataset, sparsidade, variáveis derivadas, relações ERA5-radar e extremos

Elemento	Definição
Projeto	ERA5 -> Radar Sumaré / CorrDiff
Dataset autoritativo	1.016.208 patches | 84.684 timestamps | 12 predictors ERA5 raw
Período	2011-2024
Geometria	Grade ~70 x 84 | patch 32 x 32 | stride 16 | 12 posições/timestamp
Fases	0 a 4 concluídas; Fase 4 v3.1 validada contra Fase 0
Escopo	Resultados descritivos/preditivos, sem inferência causal

Objetivo do relatório

Consolidar de forma especializada o que as Fases 0-4 estabeleceram sobre a qualidade do dataset, a distribuição do radar, a redundância dos predictors, o sinal meteorológico ERA5-radar e a estrutura dos eventos extremos. Ao final, o relatório traduz essas evidências em decisões para o CorrDiff e em argumentos para a dissertação.

Versão consolidada - outubro de 2026

Resumo executivo

As Fases 0 a 4 estabeleceram a base empírica para todo o restante do projeto. A Fase 0 mostrou que o dataset reconstruído é estruturalmente consistente, mas temporalmente incompleto: 84.684 dos 122.736 timestamps horários esperados estão disponíveis, equivalentes a 69,00% de cobertura. O dataset final contém 1.016.208 patches alinhados e 12 canais ERA5 raw. A auditoria cache -> target foi aprovada e a semântica consolidada do target é log1p da refletividade radar em dBZ após substituição de não finitos e clipping de valores negativos para zero.

A Fase 1 demonstrou que o target é fortemente zero-inflado. Apenas 1,4662% dos pixels armazenados são positivos, enquanto 29,8872% dos patches contêm ao menos um eco. A raridade cresce rapidamente com o threshold: >=45 aparece em aproximadamente 0,0700% dos pixels e 2,8164% dos patches; >=50 ocorre em apenas 163 pixels distribuídos em 71 patches. Isso torna inadequada qualquer avaliação centrada somente em métricas globais dominadas por pixels secos.

A Fase 2 introduziu oito variáveis derivadas para interpretação de umidade, estrutura térmica e diferenças vetoriais de vento, mas encontrou redundância relevante com os canais raw. A consequência metodológica foi manter os 12 canais originais como baseline e reservar as derivadas para hipóteses de representação e futuras ablações.

Nas Fases 3 e 4 surgiu uma transição robusta com a severidade. Em análises gerais, a umidade - especialmente tcwv e r_500 - apresentou as associações mais consistentes. Entre pixels positivos e em thresholds altos, a estrutura térmica ganhou importância relativa. Na Fase 4, r_500 passou de sinal fortemente positivo nos limiares baixos para negativo em >=45, indicando comportamento não monotônico e dependente do regime. A versão v3.1 reproduziu exatamente as prevalências globais da Fase 0 em todos os thresholds fixos.

Mensagem central

O conditioning ERA5 contém sinal meteorológico real, mas esse sinal não é unidimensional. Umidade caracteriza fortemente ocorrência e eventos moderados; variáveis térmicas e alguns sinais dinâmicos ganham relevância na cauda intensa. Isso justifica preservar o conjunto raw completo e avaliar o CorrDiff com métricas específicas de evento, intensidade e estrutura, em vez de selecionar canais apenas por correlação escalar.

1. Base de dados e contrato analisado

O bloco Fases 0-4 foi executado sobre o dataset reconstruído de 2011-2024, com ERA5 remapeado para a grade do radar e patches sincronizados por timestamp. As análises desta etapa descrevem a distribuição armazenada no espaço de patches; como há sobreposição, frequências pixelwise não equivalem automaticamente a uma climatologia espacial deduplicada do domínio.

Elemento	Configuração
Input	[1.016.208, 12, 32, 32]
Target / mask	[1.016.208, 1, 32, 32]
Timestamps disponíveis	84.684 de 122.736
Cobertura global	69,00%
Grade alvo	~70 x 84 pixels; ~2 km/pixel nominal
Patch / stride	32 x 32 / 16
Patches por timestamp	12
Target consolidado	log1p(dBZ clipado em zero)

1.1 Atualização documental da semântica do target

A síntese inicial das Fases 0-4 ainda usava a formulação cautelosa "valor numérico da legenda do radar". A documentação consolidada posterior do builder e a auditoria cache -> target estabeleceram a interpretação operacional usada atualmente: o cache contém dBZ; o builder substitui NaN/inf por zero, clipa valores negativos para zero e armazena log1p. O inverso expm1 reconstrói o cache clipado dentro da precisão float32. Este relatório adota essa semântica atualizada e explicitamente auditada.

Cuidado físico

Clipping de dBZ negativos elimina informação de refletividade negativa presente no produto original. O target atual representa, portanto, a refletividade não negativa após essa regra de pré-processamento.

2. Fase 0 - qualidade, cobertura e integridade

A Fase 0 teve papel de gate de qualidade. Antes de qualquer interpretação meteorológica, foram auditados shapes, mask, timestamps, valores não finitos, semântica do target e reprodução cache -> target. O resultado foi PASS estrutural.

Indicador	Resultado	Leitura
Patches	1.016.208	estrutura final reconstruída
Timestamps	84.684 / 122.736	38.052 horários ausentes
Cobertura	69,00%	principal limitação global
Primeiro disponível	2011-01-17 19 UTC	início efetivo observado
Último disponível	2024-12-31 23 UTC	fim da série
Pixels válidos armazenados	1.040.596.992 (100%)	sem inválidos no dataset final
Auditoria cache -> target	PASS; erro máx. ~7,63e-06	compatível com precisão float32

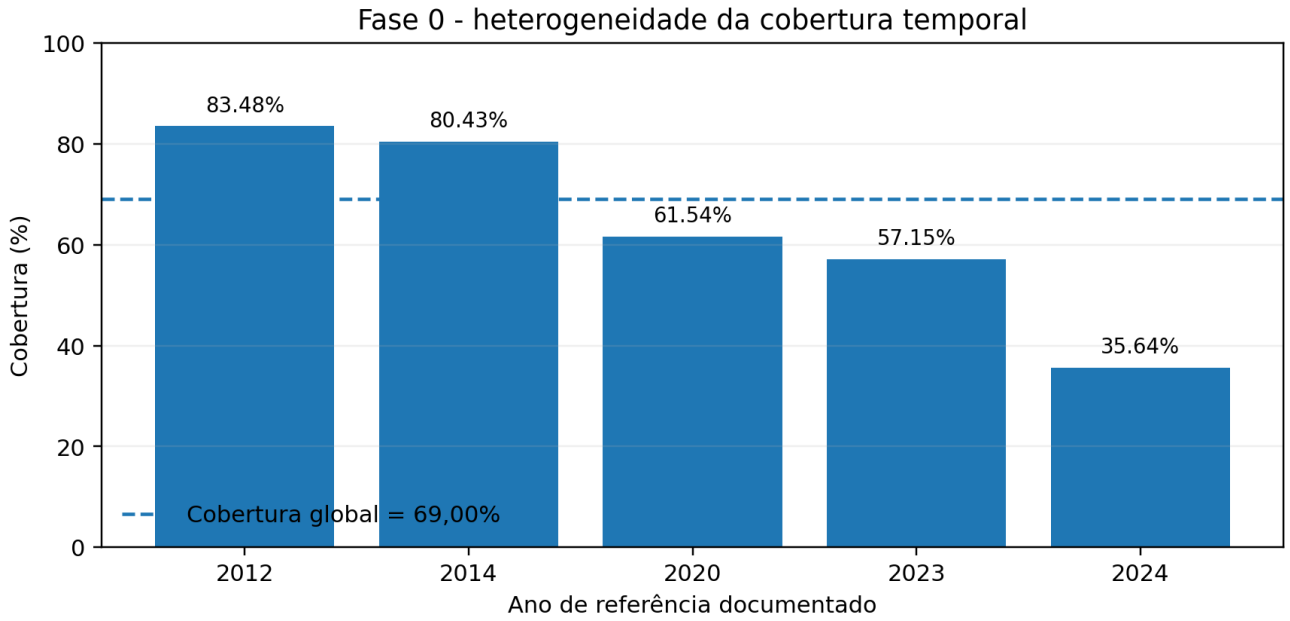


Figura 1 - Anos de referência com valores de cobertura explicitamente documentados. A figura não preenche anos cujo valor exato não está preservado na tabela de referência.

2.1 Implicações metodológicas da cobertura

- Contagens brutas por mês, ano ou estação não podem ser tratadas diretamente como climatologia; o denominador precisa respeitar a disponibilidade observacional.
- A cobertura também varia por hora UTC: entre os horários destacados no consolidado, 11 UTC teve 61,30% e 01 UTC 78,06%.
- A geometria de patches cobre 87,07% da grade 70 x 84; pixels e estruturas repetidos por overlap recebem ponderação implícita na distribuição armazenada.

Conclusão da Fase 0

O dataset é estruturalmente adequado para análise e treinamento. A principal fragilidade é a heterogeneidade temporal, que precisa acompanhar qualquer interpretação de frequência meteorológica e, mais tarde, qualquer desenho de split temporal.

3. Fase 1 - caracterização univariada e sparsidade

A Fase 1 quantificou a distribuição marginal do target e estabeleceu que o problema é severamente desbalanceado. A amostra analítica de 32.768 patches foi usada para caracterizações adicionais, sempre comparada às referências globais da Fase 0.

Evento	Fração de pixels	Fração/contagem de patches
>0	1,466204%	29,8872%
>=20	1,448884%	29,7619%
>=25	0,867680%	21,7845%
>=30	0,504830%	16,0795%
>=35	0,335772%	12,2381%
>=40	0,131927%	7,6038%
>=45	0,069954%	2,8164%
>=50	0,0000157%	71 patches / 163 pixels

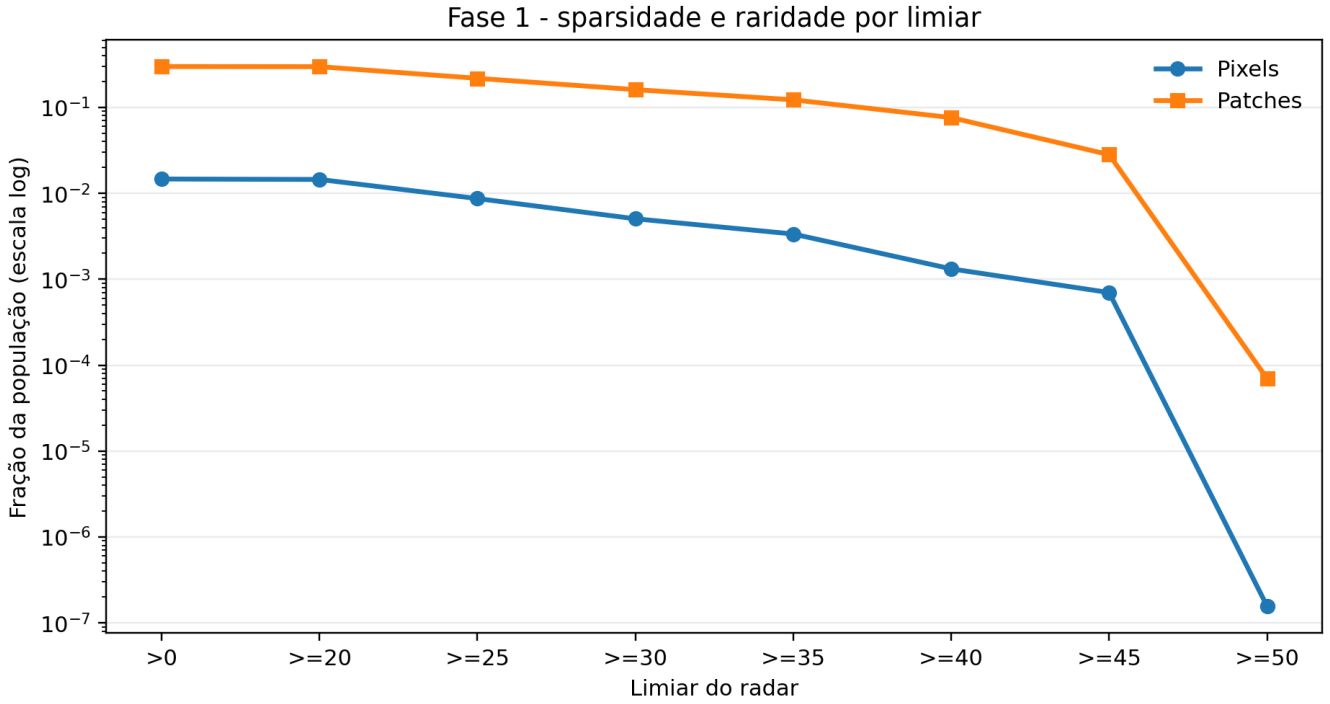


Figura 2 - Queda da prevalência em pixels e patches com o aumento do threshold. O eixo vertical é logarítmico.

3.1 Intensidade positiva e escolha de métricas

- Pixels zero representam aproximadamente 98,53% do target armazenado; quantis globais P90 e P95 são zero.
- Nos pixels positivos, a mediana é ~25 dBZ; p75/p90 ~35/40 dBZ; p95/p99 ~46,78 dBZ.
- Métricas globais como MAE/RMSE podem ser dominadas por pixels secos; thresholds fixos, métricas condicionadas ao evento e diagnósticos de extremos são necessários.

3.2 Auditorias adicionais

- A amostra de 32.768 patches teve deslocamento máximo de média de 0,161 sigma em relação às estatísticas exatas; análises amostrais devem permanecer ancoradas nas referências globais.
- r_850 contém ~1,19% e r_500 ~0,49% de valores fora de [0,100]. Eles foram medidos e mantidos sem clipping nesta etapa de auditoria.

Conclusão da Fase 1
A distribuição do radar não é apenas rara: ela é altamente zero-inflada e apresenta uma cauda extrema muito pequena. Isso obriga o protocolo de modelagem a separar pelo menos ocorrência, intensidade, localização e extremos.

4. Fase 2 - variáveis derivadas, interpretação e redundância

A Fase 2 criou oito transforms determinísticas dos 12 canais raw para tornar explícitas propriedades de magnitude de vento, diferenças térmicas, diferença de umidade e diferenças vetoriais. Na versão v2, as correlações foram calculadas em pixels alinhados entre variáveis, usando reservoir conjunto de 300.000 linhas.

Variável derivada	Definição / interpretação
wind_speed_10	sqrt(u10^2 + v10^2)
wind_speed_850	sqrt(u850^2 + v850^2)
wind_speed_500	sqrt(u500^2 + v500^2)
delta_t_500_850	t_500 - t_850
delta_t_850_surface	t_850 - t2m
delta_r_500_850	r_500 - r_850
bulk_wind_diff_10_850	norma vetorial entre ventos de 10 m e 850 hPa
bulk_wind_diff_850_500	norma vetorial entre ventos de 850 e 500 hPa

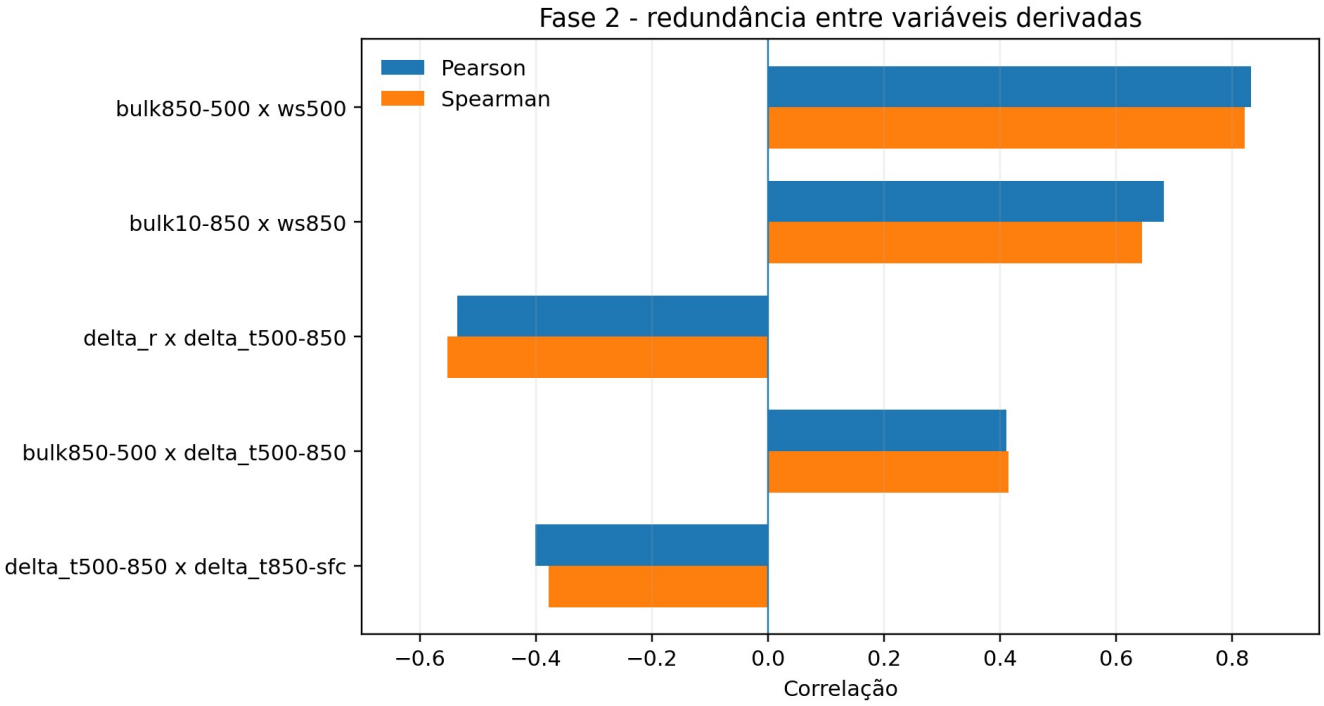


Figura 3 - Correlações documentadas entre variáveis derivadas. Pearson e Spearman concordantes confirmam redundâncias importantes.

4.1 Leitura científica

- wind_speed_500 e bulk_wind_diff_850_500 são fortemente relacionados (Pearson 0,833; Spearman 0,821).
- wind_speed_850 e bulk_wind_diff_10_850 também apresentam correlação alta (0,682 / 0,645).
- delta_r_500_850 e delta_t_500_850 apresentam associação negativa relevante (-0,535 / -0,552), mas ambas continuam sendo transformações de variáveis já presentes no input.

- bulk_wind_diff é diferença vetorial em m/s; não deve ser descrita como shear normalizado por altura. Da mesma forma, delta_t é diferença de temperatura e não deve ser automaticamente rotulado como instabilidade.

Decisão para o CorrDiff
As derivadas podem facilitar representação e interpretação, mas não adicionam informação meteorológica independente. O baseline deve preservar os 12 canais raw; derivadas devem ser testadas formalmente como representação, não tratadas como novos graus de liberdade.

5. Fase 3 - relações ERA5 x radar

A Fase 3 examinou associações entre predictors e target em uma amostra conjunta de pixels alinhados. O objetivo era identificar quais dimensões do estado ambiental apresentavam sinal descritivo de ocorrência/intensidade, sem converter correlação em causalidade ou seleção definitiva de canais.

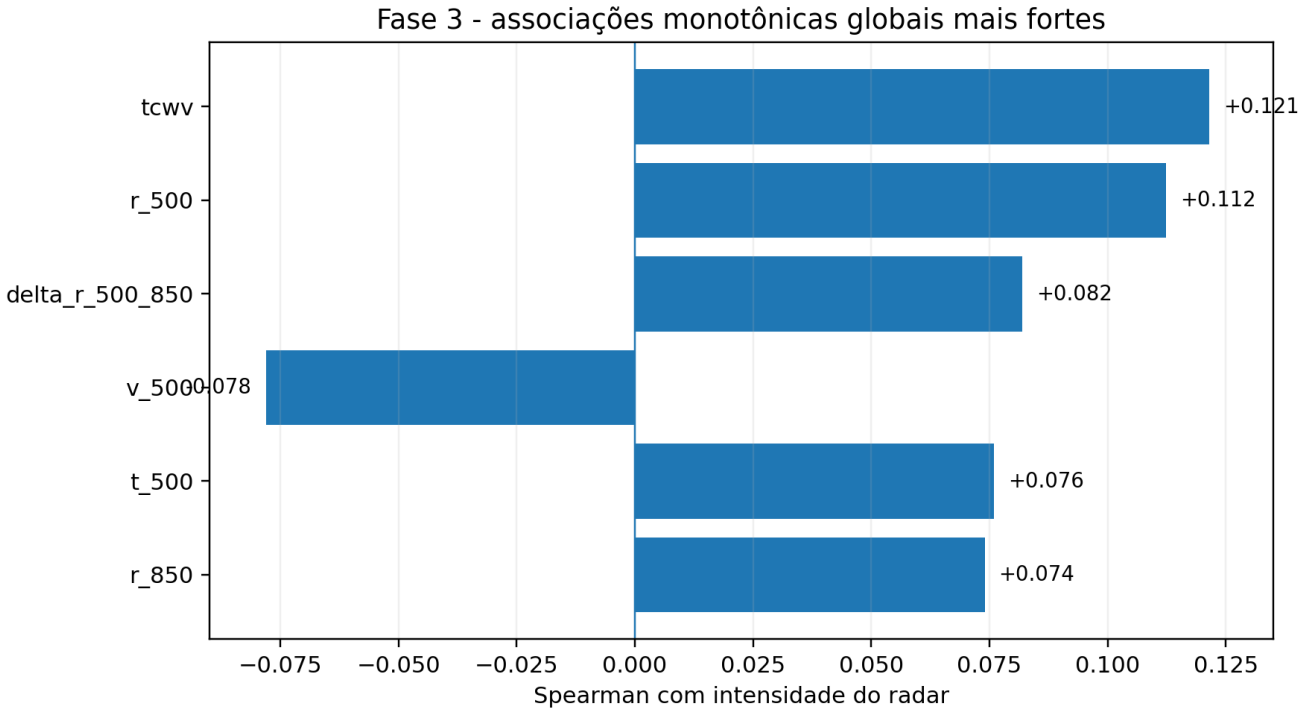
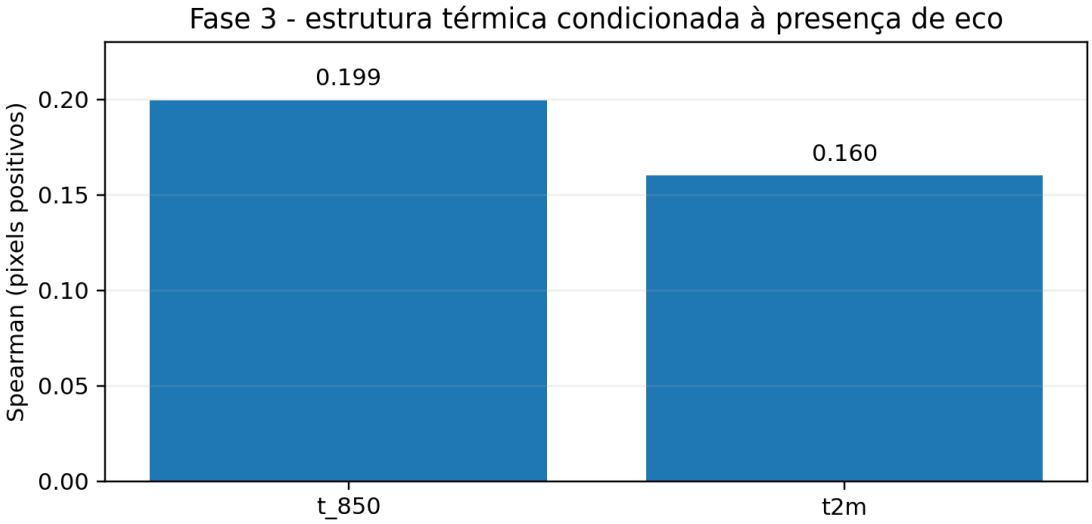


Figura 4 - Associações monotônicas globais mais fortes. tcwv e r_500 lideram o sinal na amostra geral.

Predictor	Spearman / escopo	Leitura
tcwv	+0,121	umidade da coluna / ocorrência
r_500	+0,112	umidade em 500 hPa; comportamento muda na cauda
delta_r_500_850	+0,082	gradiente de umidade interpretativo
v_500	-0,078	sinal direcional na amostra global
t_500	+0,076	estrutura térmica ganha relevância com intensidade
r_850	+0,074	umidade em baixos níveis
t_850	+0,199 em pixels positivos	maior associação condicionada à presença de eco
t2m	+0,160 em pixels positivos	ganho relativo condicionado a eco



Resultado-chave da Fase 3

A umidade diferencia melhor a ocorrência do eco na distribuição global. Depois de condicionar à existência de radar positivo, a estrutura térmica passa a explicar parcela maior da variação de intensidade. Esse resultado antecipou a análise por thresholds da Fase 4.

5.1 O que a Fase 3 não permite concluir

- Correlação pixelwise pequena não significa inutilidade de uma família para organização espacial ou interações não lineares.
- Sinais direcionais de vento não devem ser descartados com base apenas em correlações escalares.
- Nenhum coeficiente apresentado demonstra causalidade física.

6. Fase 4 - eventos intensos e extremos

A versão final v3.1 corrigiu a análise de extremos por meio de scan global do target/mask, estratos globais de intensidade, pesos inversos por estrato e avaliação direta dos thresholds no domínio armazenado. A principal validação foi a reprodução exata das prevalências da Fase 0 para todos os limiares fixos.

Limiar	Pixels exatos	Diferença vs Fase 0
>=20	15.077.040	0
>=25	9.029.055	0
>=30	5.253.244	0
>=35	3.494.030	0
>=40	1.372.827	0
>=45	727.939	0
>=50	163	0

Fase 4 - evolução dos SMDs documentados (valores aproximados do consolidado)

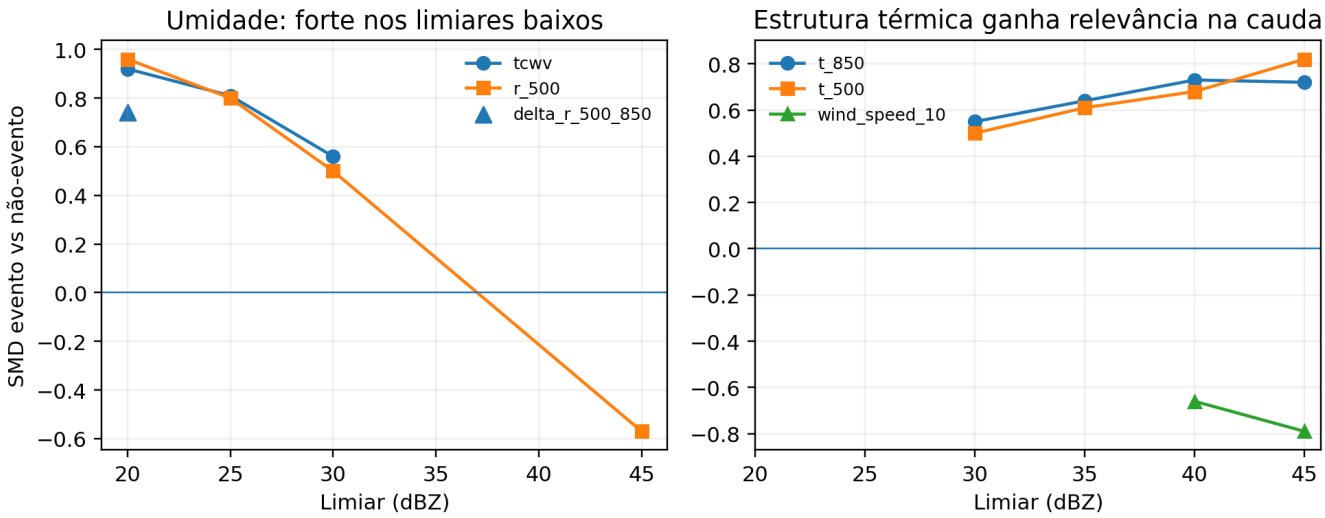


Figura 5 - SMDs documentados por limiar. Os valores são os aproximados preservados no consolidado das Fases 0-4; não foram preenchidos pontos ausentes.

Evento	SMDs documentados	Leitura
>=20	r_500 +0,96; tcwv +0,92; delta_r +0,74	ambiente fortemente úmido
>=25	tcwv +0,81; r_500 +0,80	umidade ainda dominante
>=30	tcwv +0,56; t_850 +0,55; r_500 +0,50; t_500 +0,50	zona de transição
>=35	t_850 +0,64; t_500 +0,61	estrutura térmica passa à frente
>=40	t_850 +0,73; t_500 +0,68; wind_speed_10 -0,66	regime intenso distinto
>=45	t_500 +0,82; wind_speed_10 -0,79; t_850 +0,72; r_500 -0,57	cauda intensa e inversão de r_500

6.1 Resultado mais importante: mudança de assinatura com a severidade

O padrão não é monotônico e não pode ser resumido por uma única variável. Umidade domina os limiares baixos e moderados; entre 30 e 35 dBZ aparece uma transição; acima de 35-40 dBZ a estrutura térmica assume maior destaque. Em >=45, r_500 muda de sinal, enquanto t_500, t_850 e wind_speed_10 distinguem fortemente evento e não-evento. Isso sugere ambientes distintos entre ocorrência de eco e cauda extrema, sem autorizar interpretação causal.

6.2 Ultra-raridade de >=50

O threshold >=50 contém somente 163 pixels em 71 patches. Ele deve ser tratado como auditoria da cauda e diagnóstico exploratório, não como classe principal para seleção de predictors, tuning ou conclusão robusta de generalização.

6.3 Limitação do ESS ponderado

O ESS usado na Fase 4 corrige a desigualdade introduzida pelos pesos da amostragem estratificada, mas não representa o número de eventos meteorológicos independentes. Dependência espacial por overlap e autocorrelação temporal continuam presentes.

Conclusão da Fase 4
A versão v3.1 encerrou a inconsistência de prevalência e revelou uma transição de assinatura meteorológica com a intensidade. O conjunto de conditioning deve ser avaliado por famílias e ablações controladas, não por um ranking fixo de correlações.

7. Síntese integrada das Fases 0 a 4

Fase	Pergunta	Resultado principal	Consequência
0	O dataset é confiável?	PASS estrutural; 69% de cobertura	controlar missingness e temporalidade
1	Como o target se distribui?	98,53% de pixels secos; extremos raros	métricas globais são insuficientes
2	Derivadas acrescentam informação?	há redundância relevante	raw12 como baseline; derived em ablação
3	Que predictors têm sinal?	umidade lidera global; térmica cresce em positivos	separar ocorrência de intensidade
4	O sinal muda nos extremos?	sim; transição e inversão de r_500	conditioning depende de regime/severidade

7.1 Núcleo de predictors que emerge das Fases 3-4

Os sinais mais consistentes no bloco inicial incluem tcwv, r_500, t_500, t_850, v_500 e r_850, com delta_r_500_850 útil como variável interpretativa. Isso não constitui uma lista definitiva de seleção de canais: trata-se de um núcleo descritivo que motivou análises posteriores por espaço, escala, multivariado, regimes e ablações.

7.2 O que já estava claro antes das fases espaciais

- O problema não pode ser reduzido a prever a média: a distribuição é esparsa e a cauda é meteorologicamente relevante.
- O estado ambiental contém sinal, mas a assinatura muda conforme o threshold.
- A seleção de canais precisa considerar interações e organização espacial; correlação escalar isolada é insuficiente.
- A cobertura desigual impõe avaliação temporal rigorosa e denominadores condicionados à disponibilidade observacional.

8. Limitações e cuidados de interpretação

- Cobertura temporal incompleta e heterogênea; missingness pode enviesar climatologias ingênuas.
- Patches sobrepostos duplicam pixels e estruturas; contagens armazenadas não equivalem a amostras IID.
- ERA5 remapeado para ~2 km continua limitado pela resolução efetiva do produto de origem; interpolação não cria observações meteorológicas independentes nessa escala.
- As relações das Fases 3-4 são descritivas/preditivas, não causais.
- Valores de r_850 e r_500 fora de [0,100] foram observados e mantidos na auditoria; qualquer tratamento futuro precisa ser explícito.
- Resultados >=45 têm maior incerteza; >=50 é ultra-raro e não deve sustentar sozinho seleção de variáveis.
- O target atual perde refletividade negativa devido ao clipping antes de log1p.

Nota de rigor documental
Quando um resultado só está preservado de forma aproximada no consolidado - como alguns SMDs da Fase 4 - este relatório o marca como aproximado e não inventa casas decimais ou valores ausentes.

9. Principais pontos para o CorrDiff

Preservar raw12 no baseline
As Fases 2-4 não justificam remoção precoce de vento nem substituição dos canais raw por derived. As derivadas devem ser comparadas como representação.

Tratar ocorrência e intensidade como problemas distintos
Umidade é mais informativa na ocorrência/moderados; térmica ganha importância na cauda. A loss e o protocolo de métricas precisam enxergar ambos.

Não otimizar apenas RMSE/MAE global
98,53% dos pixels são secos. Um modelo excessivamente suave pode parecer bom globalmente e falhar em >=30/40/45.

Manter thresholds físicos na avaliação
20/30/40/45 dBZ são necessários para acompanhar skill meteorologicamente relevante. >=50 deve permanecer diagnóstico secundário.

Usar ablações por famílias
A mudança de relevância com severidade sugere comparar moisture, thermal e dynamics por suficiência e necessidade condicional, em vez de ranking fixo de coeficientes.

Respeitar a temporalidade
A cobertura desigual observada já na Fase 0 antecipa a necessidade de split cronológico e testes futuros bloqueados.

Interpretar derived corretamente
delta_t e bulk_wind_diff devem ser usados como transforms de representação; não como informação independente ou rótulos físicos além do que a definição suporta.

10. Principais pontos para a dissertação

Validade do dataset
A Fase 0 fornece evidência auditável de consistência estrutural. Isso permite separar claramente problemas de qualidade estrutural de limitações observacionais de coverage.

Desbalanceamento como propriedade do problema
A sparsidade da Fase 1 não é ruído metodológico; ela é parte central da fenomenologia e explica por que métricas de evento e extremos são indispensáveis.

Convergência de evidências
Fases 3 e 4, por métodos diferentes, sustentam a transição de umidade para maior relevância térmica com o aumento da intensidade.

Não causalidade
Correlação, SMD e mutual information devem ser apresentados como associações descritivas/preditivas. A dissertação não deve converter esses resultados em causalidade física.

Raridade extrema
>=50 deve aparecer como caracterização da cauda e limitação de potência estatística, não como eixo central das conclusões.

Decisões metodológicas derivadas dos dados
Raw12 como baseline, derived em ablações, split temporal e avaliação multimetric podem ser apresentados como consequências diretas das análises, não escolhas arbitrárias posteriores.

11. Texto sugerido para Resultados e Discussão

11.1 Resultados

A auditoria inicial do dataset confirmou consistência estrutural dos tensores, máscaras e transformação do target, com 1.016.208 patches alinhados e 84.684 timestamps disponíveis de 122.736 esperados, correspondentes a 69,00% de cobertura temporal. O radar apresentou forte zero-inflation: aproximadamente 1,47% dos pixels armazenados são positivos, embora 29,89% dos patches contenham ao menos um eco. As análises ERA5-radar mostraram maior associação global de umidade, especialmente tcwv e r_500, enquanto t_850 e t2m ganharam importância relativa quando a análise foi condicionada a pixels positivos. Na análise de extremos, a assinatura mudou progressivamente com o threshold: umidade dominou os eventos moderados, enquanto t_850 e t_500 aumentaram sua capacidade discriminante na cauda intensa; em >=45 dBZ, r_500 apresentou inversão de sinal. A versão v3.1 da Fase 4 reproduziu exatamente as prevalências globais auditadas na Fase 0 em todos os thresholds fixos.

11.2 Discussão

Os resultados iniciais indicam que o condicionamento ERA5 possui informação meteorológica relevante, mas sua utilidade depende da severidade do evento. O sinal não é compatível com uma seleção univariada rígida de predictors: variáveis de umidade caracterizam melhor ocorrência e intensidade moderada, enquanto dimensões térmicas e alguns sinais dinâmicos tornam-se mais discriminantes nos eventos intensos. Em paralelo, a extrema sparsidade do target e a heterogeneidade temporal da disponibilidade radar impõem um protocolo que combine métricas de erro, eventos e extremos e que preserve separação temporal. Essas evidências justificam manter os 12 predictors raw como referência e testar transforms derivadas por ablações controladas no CorrDiff.

12. Rastreabilidade e fontes do projeto

Resultado / tema	Fonte usada
Estrutura do dataset, coverage, sparsidade, Fases 0-4	Relatorio_CorrDiff_Fases_0_a_4.pdf e Relatorio_CorrDiff_Fases_0_a_14.pdf
Semântica atualizada do target e builder	Relatorio_Tecnico_Builder_CorrDiff.pdf / documentação consolidada do builder
Definições e implementação da Fase 4 v3.1	04_compute_extreme_statistics_v3_1.py
Valores globais de referência	Apêndice A do Relatorio_CorrDiff_Fases_0_a_14.pdf

Este relatório não introduz resultados externos ao projeto. Onde houve evolução documental - particularmente na unidade/semântica do target - a versão consolidada mais recente e a auditoria do builder foram priorizadas e a mudança foi registrada explicitamente.

13. Conclusão especializada

Fases 0-1

O dataset é estruturalmente confiável, mas observacionalmente incompleto e fortemente esparso. Essas duas propriedades condicionam toda a estatística e avaliação posterior.

Fase 2

As variáveis derivadas melhoram a linguagem física e podem facilitar representação, mas são redundantes e não substituem os 12 canais raw sem teste formal.

Fases 3-4

O sinal ERA5-radar muda com a severidade: umidade domina ocorrência/moderados; estrutura térmica cresce na cauda e r_500 torna-se não monotônico. Isso favorece ablações por famílias e avaliação estratificada por threshold.

Mensagem final

As Fases 0-4 não demonstram que o ERA5 determina a estrutura radar de alta resolução; elas estabelecem algo mais fundamental: o conditioning contém informação ambiental útil, heterogênea entre regimes de intensidade, e o target exige uma modelagem que preserve eventos raros. Esse é o alicerce empírico sobre o qual as fases temporais, espaciais, multivariadas e o protocolo CorrDiff foram construídos.