CorrDiff

Relatório Especializado - Fases 13 e 14

Regimes meteorológicos, distribution shift e estabilidade temporal

Elemento	Definição
Projeto	ERA5 -> Radar Sumaré / CorrDiff
Dataset autoritativo	84.684 timestamps | 1.016.208 patches
Fase 13	Regimes meteorológicos - concluída / PASS
Fase 14	Distribution shift - concluída / PASS
Base documental	Relatório Consolidado CorrDiff - Fases 0 a 14

Escopo. Consolidar a metodologia e os resultados das Fases 13 e 14, explicando como os regimes ERA5 foram definidos, como o shift recente foi decomposto e quais decisões experimentais decorrem desses resultados para o CorrDiff e para a dissertação.

Versão consolidada - outubro de 2026

Resumo executivo

As Fases 13 e 14 formam um bloco metodológico único. A Fase 13 organiza os 84.684 timestamps do ERA5 em regimes meteorológicos recorrentes usando somente os 12 predictors raw, PCA e KMeans, sem utilizar o radar para formar os clusters. A Fase 14 reutiliza esses regimes para investigar a degradação temporal observada nos modelos multivariados da Fase 12, separando mudanças de cobertura, distribuição dos predictors, composição de regimes e mudanças condicionais dentro dos regimes.

Na Fase 13, cinco regimes foram adotados como resolução descritiva de referência. Embora o silhouette fosse maior em k=3, a solução k=5 foi extremamente estável entre seeds: ARI médio de aproximadamente 0,995 no espaço absolute e 0,988 no espaço anomaly_month_hour. Sete componentes principais explicaram cerca de 90% da variância em ambos os espaços. No espaço absoluto, R5 foi o regime mais favorável à convecção, com risk ratio de aproximadamente 2,03 para eventos >=45 dBZ. No espaço de anomalias, R5 concentrou mais eventos moderados, enquanto R4 apresentou a maior taxa de >=45 dBZ. Os regimes persistiram fortemente por 1 h, tipicamente entre 0,92 e 0,96.

Na Fase 14, o resultado mais crítico foi a heterogeneidade de cobertura do radar. A disponibilidade caiu para 57,15% em 2023 e 35,64% em 2024. Também foi detectado covariate shift real no ERA5, com t500 e tcwv apresentando mudanças mensuráveis que persistem mesmo no espaço de anomalias mês-hora. A composição dos regimes mudou: total variation de aproximadamente 0,073 no espaço absoluto e 0,088 no espaço de anomalias. Para >=45 dBZ, a taxa observada aumentou de 7,84% para 9,12%, porém o intervalo bootstrap da diferença incluiu zero. A decomposição atribuiu cerca de 69% da magnitude observada à composição de regimes no espaço absoluto e 64% no espaço de anomalias.

Conclusão integrada. O período recente é não estacionário, mas a evidência disponível não sustenta uma ruptura ampla de P(Radar | ERA5-regime). O quadro é melhor descrito como coverage shift + covariate shift + regime-composition shift, com 2024 devendo ser tratado como stress/OOD.

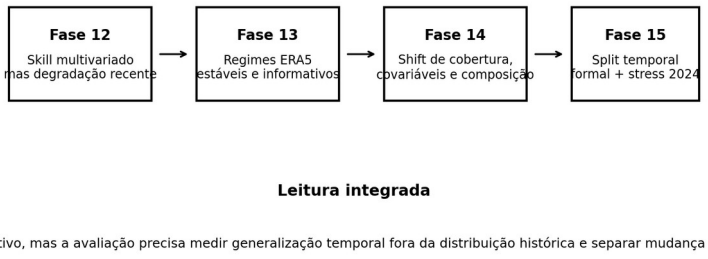


Figura 1 - Encadeamento metodológico entre a degradação da Fase 12, os regimes da Fase 13, a decomposição de shift da Fase 14 e o split formal da Fase 15.

1. Fase 13 - objetivo e desenho metodológico

A Fase 13 procurou transformar o espaço multivariado do ERA5 em uma representação discreta e interpretável de estados ambientais. A unidade de clustering deixou de ser o patch e passou a ser o timestamp. Essa escolha reduz a influência da sobreposição espacial dos patches e é compatível com a pergunta científica da fase: identificar ambientes meteorológicos recorrentes, e não objetos radar locais.

O clustering foi construído exclusivamente com os 12 predictors raw. O radar foi mantido fora do processo de formação dos regimes e usado somente depois para calcular taxas de eventos e enriquecimento. Essa separação evita target leakage e preserva a interpretação dos regimes como estados definidos pelo conditioning ERA5.

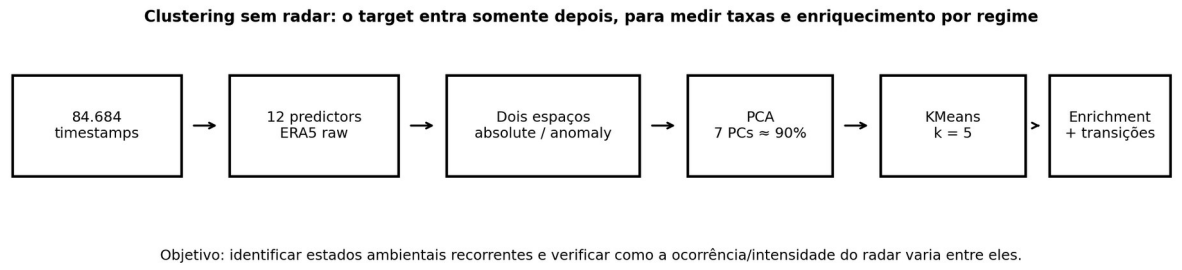


Figura 2 - Fluxo conceitual da Fase 13. O radar não participa da construção dos clusters; ele entra posteriormente na avaliação de enrichment e transições.

2. Dois espaços: absolute e anomaly_month_hour

Foram construídos dois espaços meteorológicos. O espaço absolute preserva os valores meteorológicos e, portanto, também carrega a forte sazonalidade natural do domínio. O espaço anomaly_month_hour procura remover a climatologia associada ao mês e à hora, permitindo discutir estados que são anômalos em relação ao esperado para aquele ciclo temporal.

Espaço	Pergunta principal	Resultado interpretativo
absolute	Qual é o estado meteorológico absoluto do timestamp?	Captura fortemente sazonalidade; DJF concentra-se mais em R4-R5 e JJA em R1-R3.
anomaly_month_hour	Como o estado se desvia do esperado para mês-hora?	Reduz a dominância sazonal e destaca estados atmosféricos relativos ao ciclo climatológico.

A distinção é essencial. Um regime absoluto favorável pode, em parte, representar a estação do ano. A persistência de enrichment no espaço de anomalias fornece evidência adicional de que determinados estados atmosféricos são favoráveis além da simples sazonalidade.

3. PCA, escolha de k e estabilidade

Antes do KMeans, foi aplicada PCA para reduzir a redundância entre predictors correlacionados. Em ambos os espaços, sete componentes principais foram suficientes para explicar aproximadamente 90% da variância. O clustering de referência foi então definido com k=5.

Indicador	Resultado
Timestamps	84.684
PCA para ~90% da variância	7 componentes em ambos os espaços
k de referência	5
ARI médio k=5 - absolute	~0,995
ARI médio k=5 - anomaly	~0,988
Silhouette	maior em k=3

O silhouette superior em k=3 impede interpretar cinco clusters como um número físico único de regimes. A escolha k=5 deve ser entendida como uma resolução descritiva mais fina. Seu principal argumento metodológico é a reprodutibilidade: os ARIs muito próximos de 1 mostram que diferentes inicializações do KMeans levam praticamente aos mesmos agrupamentos.

Cuidado terminológico. R1-R5 são regimes estatísticos em espaço PCA/KMeans. Não devem ser apresentados como cinco classes meteorológicas ontológicas ou como uma taxonomia física definitiva.

4. Enriquecimento dos eventos de radar por regime

Depois de congelar os regimes ERA5, foi calculada a frequência de eventos de radar dentro de cada grupo. A medida central é o risk ratio (RR), que compara a probabilidade de evento dentro do regime com a probabilidade global. RR > 1 indica enriquecimento; RR < 1 indica depleção relativa.

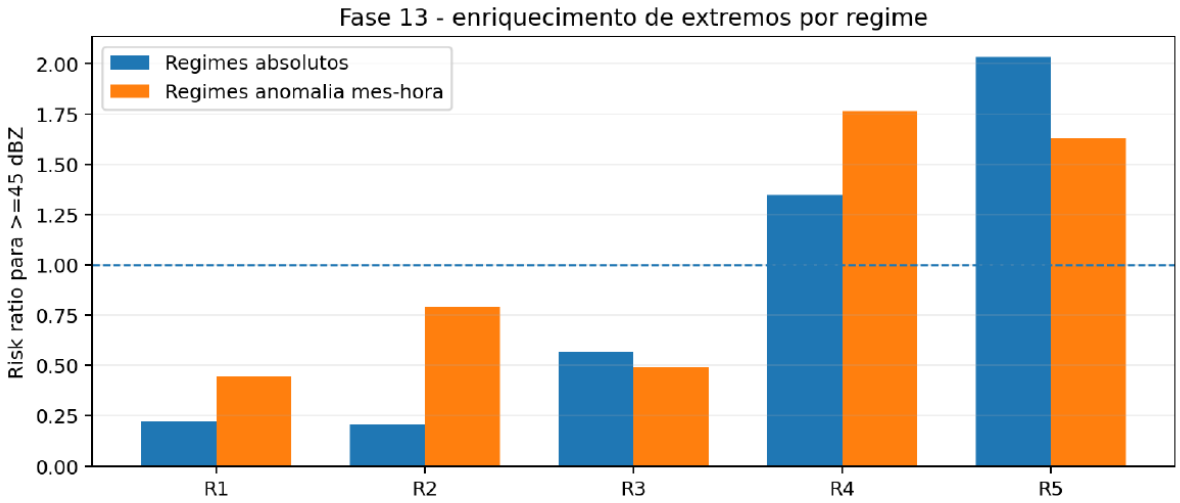


Figura 3 - Enriquecimento de >=45 dBZ nos cinco regimes de referência. Figura derivada do Relatório Consolidado CorrDiff - Fases 0 a 14.

Resultado	Valor documentado	Leitura
Absolute R5 - RR >=30	~1,89	Regime fortemente favorável a eventos moderados.
Absolute R5 - RR >=40	~1,95	Enriquecimento aumenta com o limiar.
Absolute R5 - RR >=45	~2,03	Evento extremo ocorre cerca de 2x mais frequentemente que no conjunto global.
Absolute R5 - taxa >=45	~16,17%	Principal regime convectivo no espaço absoluto.
Anomaly R4 - taxa >=45	~14,03%	Maior taxa de >=45 no espaço de anomalias.
Anomaly R4 - RR >=45	~1,76	Forte enriquecimento após remover mês-hora.

O resultado mais importante é a separação entre moderados e extremos. No espaço anomaly, R5 apresentou maior ocorrência de >=30/>=40, enquanto R4 apresentou a maior taxa de >=45. Isso reforça a evidência acumulada nas Fases 4 e 12: a umidade domina a ocorrência moderada, mas a cauda extrema é melhor caracterizada por uma combinação de umidade e estrutura térmica/dinâmica.

5. Persistência temporal e interpretação dos regimes

A probabilidade de permanecer no mesmo regime uma hora depois foi muito alta, tipicamente entre 0,92 e 0,96. Esse resultado é coerente com o ERA5 descrevendo um ambiente meteorológico que evolui lentamente em comparação com a estrutura radar de alta resolução.

Essa persistência não significa persistência da mesma tempestade. O regime representa o estado ambiental; dentro dele, células de radar podem nascer, deslocar-se, intensificar-se e dissipar-se. A leitura integrada é, portanto, ambiente lento + realização radar rápida.

Conclusão da Fase 13. Eventos intensos ocorrem em mais de um tipo de ambiente favorável. O regime mais úmido domina eventos moderados, enquanto um regime com assinatura térmica/dinâmica específica apresenta maior enriquecimento relativo de >=45 dBZ.

6. Fase 14 - pergunta científica e decomposição do shift

A Fase 14 foi motivada pela degradação de generalização identificada na Fase 12. Em vez de rotular a mudança recente como concept drift, a análise separou quatro mecanismos: coverage shift, covariate shift, mudança da composição dos regimes e conditional shift dentro dos regimes. A comparação central foi 2011-2022 versus 2023-2024.

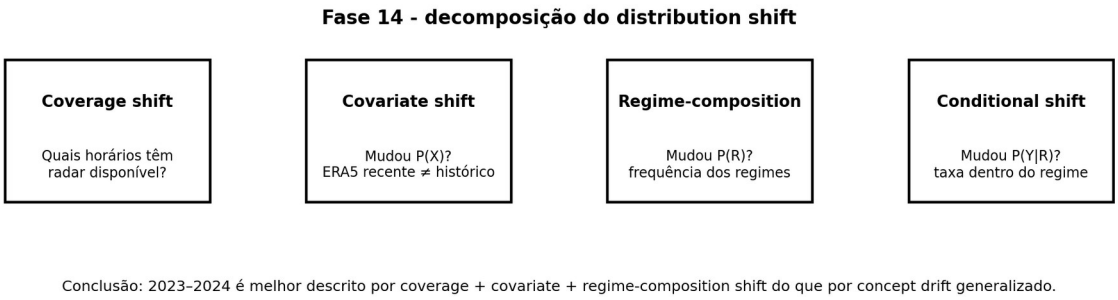


Figura 4 - Componentes avaliados na Fase 14. A decomposição evita confundir mudanças de cobertura/distribuição com uma ruptura condicional da relação ERA5-Radar.

7. Coverage shift: a principal limitação operacional

A heterogeneidade da disponibilidade do radar foi o resultado mais crítico. A cobertura global aproximada é 69%, porém 2023 apresentou somente 57,15% e 2024 apenas 35,64% dos horários esperados. Também foram documentados gaps longos, incluindo intervalos de aproximadamente 707 e 540 horas.

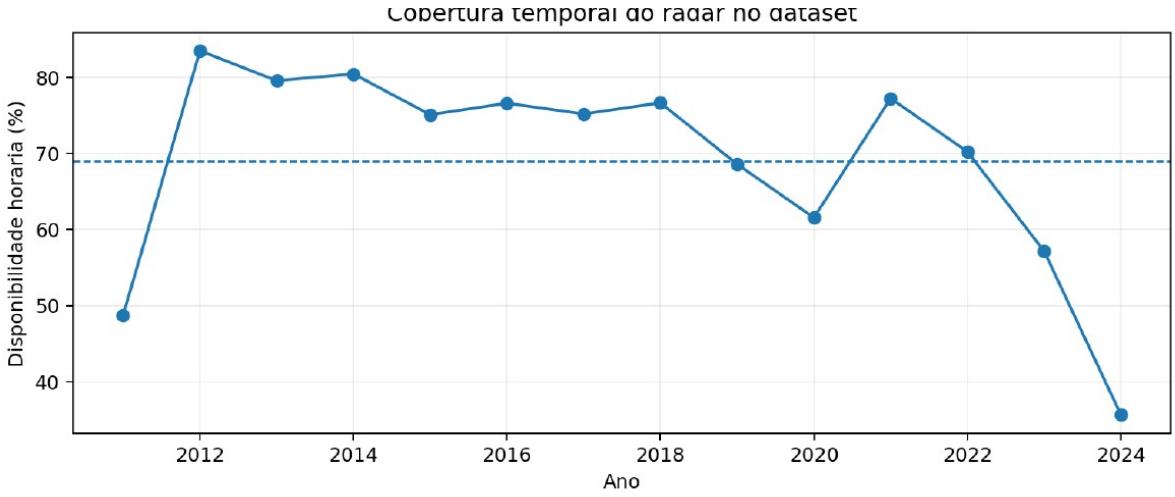


Figura 5 - Cobertura anual do radar. A linha tracejada representa a cobertura global aproximada de 69%. Figura derivada do Relatório Consolidado CorrDiff - Fases 0 a 14.

Consequentemente, métricas de 2024 descrevem apenas o subconjunto de horários observados pelo radar. Como o missingness pode estar relacionado à estação ou a sistemas meteorológicos, 2024 não deve ser tratado como climatologia anual uniforme. Essa foi a principal razão para classificá-lo posteriormente como stress/OOD.

8. Covariate shift no ERA5

A comparação entre o período histórico e o período recente demonstrou mudança real na distribuição dos predictors. O relatório preserva, em particular, os resultados de t500 e tcwv. As mudanças continuam detectáveis após remover a climatologia mês-hora, indicando que não são apenas consequência de uma composição diferente de estações ou horários.

Predictor / comparação	SMD absolute	SMD anomaly mês-hora	PSI
t500 - 2011-2022 vs 2023-2024	~0,348	~0,388	não consolidado nesta tabela
tcwv - 2011-2022 vs 2023-2024	~0,198	~0,234	não consolidado nesta tabela
t500 - 2024 isolado	~0,648	-	~0,436

SMD resume o deslocamento de localização em unidades padronizadas; PSI captura mudanças mais amplas na distribuição. Os valores de 2024, sobretudo para t500, mostram que o stress set está significativamente deslocado em relação ao histórico. Entretanto, a cobertura severamente incompleta impede separar perfeitamente mudança meteorológica real de seleção dos horários observados.

9. Regime-composition shift

Os regimes da Fase 13 permitiram decompor a não estacionariedade de forma meteorologicamente interpretável. Em 2023-2024, a distribuição dos regimes mudou: total variation de aproximadamente 0,073 no espaço absolute e 0,088 no espaço anomaly.

Mudança documentada	Magnitude
Total variation - absolute	~0,073
Total variation - anomaly	~0,088
Absolute R5	+5,14 pontos percentuais
Absolute R2	-6,37 pontos percentuais
Anomaly R4	+6,90 pontos percentuais

Esse resultado é particularmente relevante porque Absolute R5 e Anomaly R4 são justamente regimes fortemente associados a >=45 dBZ. Assim, uma maior ocupação desses estados pode elevar a taxa agregada de extremos mesmo que a probabilidade de evento dentro de cada regime permaneça estável.

10. Mudança da taxa >=45 e decomposição composição vs within-regime

A taxa observada de >=45 dBZ aumentou de aproximadamente 7,84% no período histórico para 9,12% em 2023-2024, uma diferença observada de 1,28 ponto percentual. Entretanto, o intervalo bootstrap da diferença inclui zero, de modo que o aumento marginal não deve ser apresentado como estatisticamente conclusivo.

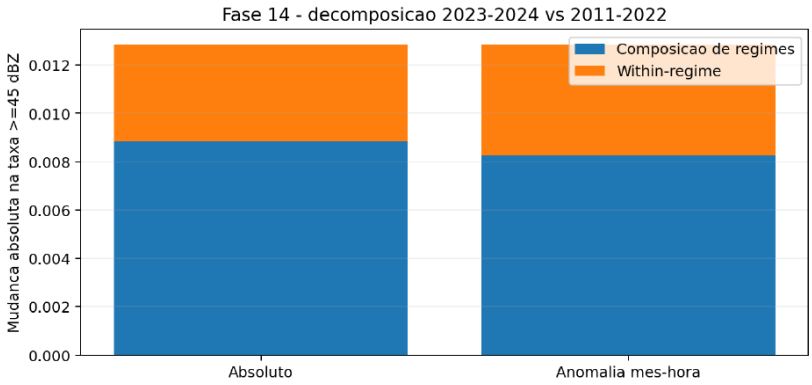


Figura 6 - Decomposição da mudança observada de >=45 dBZ em 2023-2024. Figura derivada do Relatório Consolidado CorrDiff - Fases 0 a 14.

Espaço	Parcela da magnitude associada à composição	Parcela residual within-regime
absolute	~69%	~31%
anomaly_month_hour	~64%	~36%

A concordância entre os dois espaços é forte: a maior parte da mudança observada é compatível com uma mistura diferente de regimes meteorológicos. O componente within-regime existe na decomposição, mas precisa ser interpretado junto com sua incerteza; ele não constitui, por si só, prova de concept drift.

11. Evidência de conditional/concept shift

A análise comparou a taxa de >=45 dentro dos mesmos regimes entre o período histórico e o recente. Nos regimes anomaly, todos os intervalos de conditional shift >=45 atravessaram zero. Nos principais regimes absolute R4-R5, as taxas permaneceram praticamente estáveis. Assim, a evidência de ruptura condicional generalizada é fraca.

Conclusão da Fase 14. O dataset é não estacionário, porém 2023-2024 é melhor descrito por coverage shift + covariate shift + regime-composition shift do que por uma quebra ampla de P(Radar | ERA5-regime). 2024 deve ser tratado como stress/OOD.

12. Interpretação integrada das Fases 13 e 14

As duas fases juntas oferecem uma explicação mais refinada para a generalização temporal. A Fase 13 demonstra que o ERA5 ocupa estados ambientais recorrentes e altamente estáveis, cada um com risco radar distinto. A Fase 14 mostra que o período recente mudou tanto no espaço contínuo dos predictors quanto na frequência desses estados. Portanto, uma queda de desempenho do modelo pode refletir exposição a uma nova mistura de condições meteorológicas, e não necessariamente uma falha súbita da relação física aprendida.

Pergunta	Resposta sustentada pelas Fases 13-14
O ERA5 contém estrutura ambiental recorrente?	Sim. k=5 é uma resolução descritiva altamente reprodutível (ARI ~0,995/~0,988).
Regimes diferentes têm riscos radar diferentes?	Sim. Absolute R5 chega a RR ~2,03 para >=45; Anomaly R4 apresenta taxa >=45 ~14,03%.
2023-2024 é igual ao histórico?	Não. Há forte coverage shift, covariate shift e mudança na composição dos regimes.
A taxa >=45 recente aumentou de forma conclusiva?	A taxa observada aumentou 7,84% -> 9,12%, mas o CI bootstrap da diferença inclui zero.
Há concept drift generalizado?	A evidência é fraca; within-regime não mostra quebra robusta generalizada.

13. Principais pontos para o CorrDiff

- O conditioning ERA5 é informativo em nível de regime: diferentes estados ambientais têm probabilidades de evento claramente distintas. O modelo deve explorar essa informação sem confundir regime ambiental com uma realização espacial radar determinística.
- A alta persistência dos regimes (0,92-0,96 em 1 h) reforça a separação entre ambiente lentamente variável e estrutura radar de alta resolução mais rápida. Isso é coerente com um estágio regressivo para o componente previsível e um estágio generativo para a variabilidade espacial residual.
- A generalização temporal deve ser medida explicitamente. 2023 é adequado como teste primário temporal; 2024 deve permanecer separado como stress/OOD por causa da cobertura de 35,64% e do covariate shift.
- Normalização, seleção de canais, arquitetura, loss e hiperparâmetros não devem usar 2023/2024. A existência de covariate shift torna ainda mais importante ajustar transformações somente no train.
- Uma queda de performance em 2024 não deve ser interpretada isoladamente como falha do CorrDiff. Deve ser analisada junto com regime occupancy, coverage, estação e shifts de predictors.
- A avaliação final deve reportar resultados por threshold e, quando possível, por regime/estação, pois frequência, intensidade e composição ambiental não são equivalentes.

14. Principais pontos para a dissertação

- A escolha do CorrDiff passa a ser sustentada não apenas por separação de escalas, mas também por multimodalidade ambiental: eventos intensos surgem em mais de um regime favorável, e o mesmo tipo de ambiente pode suportar múltiplas realizações radar.
- A Fase 13 fornece uma descrição não supervisionada e sem target leakage dos estados ERA5; isso fortalece a argumentação de que o condicionamento possui estrutura meteorológica própria e não foi definido artificialmente a partir do radar.

- A Fase 14 evita o uso impreciso do termo concept drift. A dissertação pode demonstrar que coverage, covariate e regime-composition shift foram avaliados separadamente antes de discutir mudança condicional.
- O aumento observado de >=45 em 2023-2024 deve ser apresentado com sua incerteza: a diferença existe na amostra, mas o intervalo bootstrap inclui zero.
- 2024 deve ser descrito como stress/OOD temporalmente selecionado, e não como representação uniforme da climatologia anual. Essa distinção é essencial para a validade externa das conclusões.
- Os regimes KMeans são estados estatísticos no espaço PCA; não devem ser convertidos em classes meteorológicas físicas rígidas nem usados para inferências causais.

15. Texto sugerido para a seção de Resultados

"A análise de regimes meteorológicos identificou cinco estados de referência altamente reprodutíveis no espaço multivariado dos predictors ERA5, com ARI médio de aproximadamente 0,995 no espaço absoluto e 0,988 no espaço de anomalias mês-hora. Os regimes apresentaram taxas de eventos radar substancialmente distintas. No espaço absoluto, R5 apresentou risk ratio de aproximadamente 2,03 para eventos >=45 dBZ, enquanto no espaço de anomalias R4 concentrou a maior taxa de >=45. A persistência horária dos regimes foi elevada (0,92-0,96), indicando evolução ambiental mais lenta que a estrutura radar de alta resolução."

"A análise de distribution shift demonstrou redução importante da cobertura radar em 2023 (57,15%) e, principalmente, em 2024 (35,64%), além de covariate shift em predictors como t500 e tcwv e mudança mensurável na composição dos regimes. Embora a taxa observada de >=45 dBZ tenha passado de 7,84% para 9,12% no período recente, o intervalo bootstrap da diferença incluiu zero. A decomposição atribuiu aproximadamente 64-69% da magnitude da mudança à composição de regimes, e a evidência de conditional shift generalizado permaneceu fraca."

16. Texto sugerido para a Discussão

"Os resultados das Fases 13 e 14 sugerem que a dificuldade de generalização temporal não deve ser interpretada primariamente como ruptura da relação ERA5-Radar. O período recente combina menor cobertura observacional, mudança na distribuição dos predictors e alteração da frequência de regimes meteorológicos favoráveis. Essa distinção é relevante para a avaliação de modelos generativos: desempenho fora da distribuição deve ser analisado em conjunto com o contexto ambiental e a disponibilidade observacional. A persistência e o enriquecimento dos regimes também reforçam que o ERA5 fornece informação sobre o estado ambiental, enquanto a realização espacial de alta resolução permanece parcialmente indeterminada, sustentando a modelagem probabilística condicional."

17. Limitações e cautelas de interpretação

- A cobertura do radar é incompleta e temporalmente heterogênea; missingness pode estar associado a estação ou sistemas meteorológicos.
- Resultados >=45 têm maior incerteza por raridade; ausência de evidência robusta de conditional shift não prova estacionaridade perfeita.
- Bootstraps diários preservam dependência intra-dia, mas não eliminam dependência entre dias consecutivos de um mesmo sistema.
- Regimes KMeans são aproximações geométricas no espaço PCA e não classes meteorológicas ontológicas.
- As associações e decomposições são descritivas/preditivas; não demonstram causalidade física nem mudança climática.
- Os resultados de 2024 combinam shift meteorológico potencial com forte seleção observacional devido à cobertura muito baixa.

18. Rastreabilidade dos resultados

Resultado usado neste relatório	Fonte consolidada
84.684 timestamps; PCA 7 PCs; k=5; ARI 0,995/0,988	Relatório Consolidado, Fase 13, p. 12
RR Absolute R5 >=30/>=40/>=45; persistência 0,92-0,96	Relatório Consolidado, Fase 13, p. 12
Absolute R5 >=45 16,17%; Anomaly R4 >=45 14,03% e RR 1,76	Apêndice A do Relatório Consolidado, p. 16
Coverage 2023/2024; SMD/PSI; total variation; mudanças de ocupação	Relatório Consolidado, Fase 14, p. 13
>=45 7,84% -> 9,12%; CI inclui zero; decomposição 64-69%	Relatório Consolidado, Fase 14, p. 13
Limitações de coverage, KMeans, bootstrap e causalidade	Relatório Consolidado, p. 16

Outputs registrados no consolidado para estas fases incluem: regime_assignments.parquet, regime profiles, enrichment, transitions, crosswalk; e, para a Fase 14, outputs de coverage, predictor shift, regime composition shift, conditional shift e event_rate_decomposition.parquet. O relatório atual não preenche parâmetros de implementação que não estejam documentados no consolidado; detalhes finos devem ser recuperados desses artefatos originais caso sejam necessários para tabelas metodológicas definitivas.

19. Conclusão especializada

Fase 13. O ERA5 apresenta regimes ambientais recorrentes, altamente estáveis e com risco radar muito diferente. A associação com extremos não é unidimensional: umidade explica grande parte da favorabilidade moderada, mas extremos também se concentram em estados com assinatura térmica/dinâmica específica.

Fase 14. O período 2023-2024 é não estacionário principalmente por cobertura, covariáveis e composição dos regimes. A maior parte da mudança observada de >=45 é associada à composição de regimes; a evidência de concept drift generalizado é fraca. 2024 deve permanecer como stress/OOD separado.

Mensagem final para o CorrDiff e a dissertação. O conditioning ERA5 é meteorologicamente estruturado e informativo, mas a avaliação deve distinguir ambiente, realização radar e distribuição temporal. O desenho experimental deve preservar splits cronológicos, testes bloqueados, análise separada de 2023 e 2024 e interpretação cuidadosa de performance sob shift.

Referência documental principal

Relatório_CorrDiff_Fases_0_a_14.pdf. Seções 2.14 (Fase 13), 2.15 (Fase 14), síntese integrada, limitações acumuladas e apêndices de números/outputs. Projeto de Mestrado ERA5 -> Radar Sumaré / CorrDiff.